

INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA  
DO SUDESTE DE MINAS GERAIS - CAMPUS RIO POMBA

Thays Lacerda Corrêa

**Uma Metodologia de Segmentação e  
Classificação de Imagens Laterais  
Infravermelhas para o Auxílio no Diagnóstico  
do Câncer de Mama**

Rio Pomba

2019

Thays Lacerda Corrêa

# **Uma Metodologia de Segmentação e Classificação de Imagens Laterais Infravermelhas para o Auxílio no Diagnóstico do Câncer de Mama**

Trabalho de Conclusão apresentado ao Campus Rio Pomba, do Instituto Federal de Educação, Ciência e Tecnologia do Sudeste de Minas Gerais, como parte das exigências do curso de Bacharelado em Ciência da Computação para a obtenção do título de Bacharel em Ciência da Computação.

Orientador: Dr. Lucas Grassano Lattari

Coorientador: Bel. Matheus de Oliveira Freitas Baffa

Rio Pomba

2019

**Ficha Catalográfica elaborada pela Biblioteca Jofre Moreira – Instituto Federal de Educação, Ciência e Tecnologia do Sudeste de Minas Gerais - Campus Rio Pomba**

C824u

Corrêa, Thays Lacerda.

Uma metodologia de segmentação e classificação de imagens laterais infravermelhas para o auxílio no diagnóstico do câncer de mama./ Thays Lacerda Corrêa – Rio Pomba, 2019.

44f. : il.

Orientador: Prof. Lucas Grassano Lattari.

Co-orientador: Matheus de Oliveira Freitas Baffa.

Trabalho de Conclusão de Curso (Graduação em Computação) - Instituto Federal de Educação, Ciência e Tecnologia do Sudeste de Minas Gerais - Campus Rio Pomba.

1. Processamento de imagens. 2. Sistema de informação. I. Lattari, Lucas Grassano. II. Baffa, Matheus de Oliveira Freitas. III. Título.

CDD: 004

Thays Lacerda Corrêa

## **Uma Metodologia de Segmentação e Classificação de Imagens Laterais Infravermelhas para o Auxílio no Diagnóstico do Câncer de Mama**

Trabalho de Conclusão apresentado ao Campus Rio Pomba, do Instituto Federal de Educação, Ciência e Tecnologia do Sudeste de Minas Gerais, como parte das exigências do curso de Bacharelado em Ciência da Computação para a obtenção do título de Bacharel em Ciência da Computação.

Trabalho aprovado. Rio Pomba, 12 de dezembro de 2019:

Lucas Grassano Lattari  
Dr. Lucas Grassano Lattari, Orientador,  
IF Sudeste MG - Rio Pomba

Matheus de Freitas O. Baffa  
Bel. Matheus de Oliveira Freitas  
Baffa, Coorientador, USP - Ribeirão Preto

Alessandra Martins Coelho  
Dra. Alessandra Martins Coelho  
IF Sudeste MG - Rio Pomba

Me. Marjorye Polinati da Silva Vecchi  
IF Sudeste MG - Rio Pomba

Rio Pomba

2019

Este trabalho é dedicado a todos  
aqueles que me inspiraram, em especial  
às crianças adultas que tiveram seus  
sonhos interrompidos por essa doença.

# Agradecimentos

A Deus, pelo dom da vida.

A minha família, por acreditar e me incentivar sempre.

Ao meu orientador Lucas Lattari e coorientador Matheus Baffa por toda sabedoria, motivação, compreensão e amizade.

A todos os docentes do Departamento Acadêmico de Ciência da Computação do Campus Rio Pomba, por toda dedicação e conhecimentos compartilhados diariamente ao decorrer dessa trajetória.

Aos meus amigos, por todo zelo, incentivo, paciência e apoio constante.

A mim, por acreditar, persistir e nunca desistir.

# Resumo

O Câncer de Mama é o segundo tipo mais frequente do mundo, sendo a doença relacionada que mais acomete mulheres. Estima-se que 28% dos novos casos de câncer são nas mamas. Contudo, a doença possui um prognóstico muito eficiente se detectada rapidamente elevando em até 95% as chances de cura. Por isso é indispensável o estudo de novas metodologias para a detecção precoce da doença. Em alguns casos, o câncer de mama pode ser desenvolvido em regiões que dificultam a detecção precoce como regiões laterais das mamas. O presente trabalho objetiva-se na elaboração de um novo método capaz de segmentar, analisar e classificar imagens infravermelhas laterais, retiradas nos ângulos de 45° e 90°, da região mamária, informando a existência ou não de anomalias nas mamas. A metodologia aplicada no trabalho proposto consiste em três etapas, a primeira etapa consiste na obtenção das imagens infravermelhas laterais contidas em uma base de dados pública para pesquisa em mastologia (DMR - *Database for Mastology Research*). O presente trabalho faz uso de 849 imagens, sendo 683 pertencentes a pacientes saudáveis e 166 imagens de pacientes com a doença. A segunda é a utilização do descritor de Histogramas de Gradientes Orientados juntamente com um algoritmo de Aprendizado de Máquina para a realização da segmentação das imagens. A terceira etapa consiste no processo de classificação das imagens e obtenção do diagnóstico do paciente, através de algoritmos clássicos de Aprendizado de Máquina. Os resultados obtidos em ambas as etapas, segmentação e classificação, se mostraram satisfatórios ao serem comparados com outras metodologias.

**Palavras-chaves:** câncer de mama. classificação. imagens infravermelhas. segmentação.

# Abstract

Breast cancer is the second most common type in the world, being the related disease that most affects women. It is estimated that 28% of new cancer cases are in the breasts. However, the disease has a very efficient prognosis if detected quickly, increasing the chances of cure by up to 95%. Therefore, the study of new methodologies for early detection of the disease is indispensable. In some cases, breast cancer may develop in regions that hinder early detection as lateral breast regions. The present work aims to develop a new method capable of segmenting, analyzing and classifying lateral infrared images, taken at the 45° and 90° angles of the mammary region, informing the existence or not of breast anomalies. The methodology applied in the proposed work consists of three steps, the first step is to obtain the lateral infrared images contained in a public database for mastology research (DMR - Database for Mastology Research). The present study uses 849 images, 683 from healthy patients and 166 images from patients with the disease. The second is the use of the Oriented Gradient Histogram descriptor together with a Machine Learning algorithm to perform image segmentation. The third step consists of the procedure of image classification and obtaining the patient's diagnosis through classical Machine Learning algorithms. The results obtained in both stages, segmentation and classification, were satisfactory when compared with other methods.

**Key-words:** breast cancer. classification. infrared images. segmentation.

# Listas de ilustrações

Figura 1 – Imagens térmicas utilizadas sob o protocolo estático lateral nos ângulos de 45° e 90°. Fonte: (PROENG, 2012).	3
Figura 2 – Imagem térmica frontal das mamas sob aquisição estática. Fonte: (PROENG, 2012).	9
Figura 3 – Imagens térmicas frontais das mamas sob aquisição dinâmica. Fonte: (PROENG, 2012).	9
Figura 4 – Classificação Linear do SVM. Fonte: (SOUZA, 2019).	13
Figura 5 – Problema linearmente separável em dimensão $\mathbb{R}^3$ . Fonte: (SOUZA, 2019).	13
Figura 6 – Exemplo de uma Árvore de Decisão para uma situação fictícia. Fonte: (LUCIDCHART, 2019).	16
Figura 7 – Classificação de um elemento desconhecido através da análise dos K-vizinhos. Fonte: (VIDHYA, 2018).	18
Figura 8 – Imagem térmica lateral esquerda da mama no ângulo de 90°. (a) Imagem original advinda da base de dados. (b) Imagem convertida em escala de cinza. Fonte: (OLIVEIRA, 2012).	21
Figura 9 – Etapas do Método de Segmentação de Oliveira: (a) Imagem térmica em escala de cinza. (b) Limiarização. (c) Remoção de elementos indesejáveis. (d) Detecção e refinamento de cantos. (e) Segmentação final. Fonte: (OLIVEIRA, 2012).	22
Figura 10 – Obtenção da região anormal das mamas. Fonte: (FRANCIS; SASIKALA; SARANYA, 2014).	23
Figura 11 – Imagens infravermelhas frontais sob o protocolo dinâmico. Fonte: (PROENG, 2012) apud (BAFFA; LATTARI, 2018).	25
Figura 12 – Imagens infravermelhas laterais das mamas no ângulos de 45° e 90°. Fonte: (PROENG, 2012) apud (BAFFA; LATTARI, 2018).	28
Figura 13 – Imagens infravermelhas das mamas nos ângulos de 45° e 90° em escala de cinza. Fonte: (PROENG, 2012).	29
Figura 14 – Fragmentos recortados das imagens. Fonte: Autora	30

Figura 15 – Imagem segmentada pela etapa de segmentação proposta. Fonte: Autora.	31
Figura 16 – Taxas de acurácia dos Métodos de Classificação. . . . .	36
Figura 17 – Taxas de sensibilidade dos Métodos de Classificação. . . . .	38
Figura 18 – Taxas de especificidade dos Métodos de Classificação. . . . .	39

# **Lista de tabelas**

Tabela 1 – Tabela comparativa dos Exames Médicos por Imagem. . . . .	8
Tabela 2 – Comparação de resultados entre (OLIVEIRA, 2012) e o presente trabalho. . . . .	34
Tabela 3 – Comparação de resultados entre (FRANCIS; SASIKALA; SARANYA, 2014) e o presente trabalho. . . . .	35
Tabela 4 – Resultado da acurácia em todos os métodos de classificação. . . . .	36
Tabela 5 – Resultado da Sensibilidade na Etapa de Classificação. . . . .	37
Tabela 6 – Resultado da Especificidade na Etapa de Classificação. . . . .	38

# Listas de abreviaturas e siglas

ACC	Acurácia
BMP	<i>Bitmap</i>
CNN	<i>Convolutional Neural Network</i>
DMR	<i>Database For Mastology Research</i>
DT	Árvore de Decisão
EP	Especificidade
FN	Falso Negativo
FP	Falso Positivo
HOG	<i>Histogram of oriented gradients</i>
INCA	Instituto Nacional do Câncer
JPG	<i>Joint Photographic Experts Group</i>
KNN	<i>K-Nearest Neighbors</i>
LR	Rregressão Logística
NB	<i>Naive Bayes</i>
PNG	<i>Portable Network Graphics</i>
PNP	Preditividade Negativa
PDP	Preditividade Positiva
RBF	<i>Radial Basis Function</i>
RAM	<i>Random Access Memory</i>
RF	Floresta Randômica
RNA	Rede Neural Artificial

RM	Ressonância Magnética
SEN	Sensibilidade
SVM	<i>Support Vector Machine</i>
UFF	Universidade Federal Fluminense
VN	Verdadeiro Negativo
VP	Verdadeiro Positivo

# Sumário

<b>Introdução . . . . .</b>	<b>2</b>
<b>2 Fundamentação Teórica . . . . .</b>	<b>5</b>
2.1 Câncer de Mama . . . . .	5
2.1.1 Tipos de Câncer de Mama . . . . .	5
2.1.1.1 Carcinoma Ductal <i>in Situ</i> . . . . .	5
2.1.1.2 Carcinoma Ductal Invasivo . . . . .	6
2.1.1.3 Carcinoma Lobular <i>in Situ</i> . . . . .	6
2.1.1.4 Carcinoma Lobular Invasivo . . . . .	6
2.1.1.5 Doença de Paget . . . . .	6
2.2 Exames de Diagnóstico por Imagem . . . . .	6
2.3 Imagens Infravermelhas . . . . .	7
2.4 Protocolos de Aquisição . . . . .	8
2.4.1 Aquisição Estática . . . . .	8
2.4.2 Aquisição Dinâmica . . . . .	9
2.5 Segmentação de Imagens . . . . .	10
2.5.1 Método de Segmentação . . . . .	10
2.5.1.1 Histogramas de Gradientes Orientados . . . . .	11
2.6 Classificação de Imagens . . . . .	11
2.6.1 Métodos de Classificação . . . . .	12
2.6.1.1 Máquinas de Vetores Suporte . . . . .	12
2.6.1.2 Regressão Logística . . . . .	14
2.6.1.3 Naive Bayes . . . . .	14
2.6.1.4 Árvore de Decisão . . . . .	15
2.6.1.5 Floresta Randômica . . . . .	16
2.6.1.6 <i>K-Nearest Neighbors</i> . . . . .	17
2.7 Métricas de Acurácia para Segmentação de Imagens . . . . .	18
2.8 Medidas Estatísticas para Segmentação de Imagens . . . . .	19
2.9 Medidas Estatísticas para Classificação de Imagens . . . . .	20

<b>3 Trabalhos Relacionados . . . . .</b>	<b>21</b>
3.1 (OLIVEIRA, 2012) . . . . .	21
3.2 (FRANCIS; SASIKALA; SARANYA, 2014) . . . . .	23
3.3 (BAFFA; LATTARI, 2018) . . . . .	24
3.4 (LESSA; MARENCONI, 2016) . . . . .	26
<b>4 Metodologia . . . . .</b>	<b>28</b>
4.1 Algoritmo Proposto . . . . .	28
4.1.1 Obtenção das Imagens . . . . .	28
4.1.2 Segmentação . . . . .	29
4.1.3 Classificação . . . . .	32
<b>5 Resultados . . . . .</b>	<b>34</b>
5.1 Resultados da Segmentação . . . . .	34
5.2 Resultados da Classificação . . . . .	35
5.2.1 Acurácia . . . . .	36
5.2.2 Sensibilidade . . . . .	37
5.2.3 Especificidade . . . . .	38
<b>6 Conclusão . . . . .</b>	<b>40</b>
<b>Referências . . . . .</b>	<b>42</b>

# Introdução

O carcinoma mamário, ou câncer de mama, é a formação de um tumor causado pela multiplicação desordenada de células anormais, desenvolvendo um ou mais nódulos nas mamas. Existem diferentes tipos de câncer de mama em que cada tumor possui características próprias, levando alguns a se desenvolverem de forma rápida, enquanto outros podem apresentar uma certa lentidão no crescimento. É uma doença relativamente rara de ocorrer antes dos 35 anos de idade, contudo sua incidência cresce progressivamente após os 50 anos de idade (INCA, 2019a).

O câncer de mama é o segundo tipo mais frequente no mundo, de acordo com o Instituto Nacional do Câncer - INCA (2019a), sendo o que mais acomete mulheres após o período da menopausa. Segundo o *American Cancer Society* (2019), a cada oito mulheres que viverem até os 75 anos de idade, uma estará propensa a desenvolver a doença no decorrer da vida.

De acordo com o Ministério da Saúde (2019), 28% dos novos casos de câncer em mulheres são carcinomas mamários. Este também está presente em homens, porém com menos ocorrências, ocasionando apenas 1% do total de casos da doença. Para 2019 foram estimados 59.700 novos casos de câncer de mama no Brasil (INCA, 2019a).

O câncer de mama é a quinta causa de morte mais comum ligada ao câncer no mundo. De acordo com as estimativas do INCA (2018), em 2015 foram registrados 15.403 óbitos pela doença. No Brasil a taxa de mortalidade causada pelo câncer de mama se eleva nas Regiões Sul, Sudeste e Centro-Oeste, respectivamente.

Apesar de ser um câncer com um índice elevado de ocorrências, o mesmo apresenta um bom prognóstico se identificado nos estágios iniciais. De acordo com o Hospital do Câncer de Barretos (2015), estima-se que o diagnóstico precoce eleve em até 95% as chances de cura.

Atualmente existem diversos métodos adotados pela Medicina para o diagnóstico do câncer de mama. Dentre eles, o mais comum é o autoexame, em que a pessoa percebe a presença de nódulos, eritema (vermelhidão na pele), edema (inchaço causado na pele), entre outros na região mamária. Outros exames de diagnóstico da doença são análises re-

alizadas por imagem, como a Mamografia, a Ultrassonografia e a Ressonância Magnética. Estes exames serão descritos no Capítulo 2.

Para o presente trabalho serão utilizadas imagens infravermelhas (Figura 1), também conhecidas como imagens térmicas. Este tipo de imagem captura o calor emitido por qualquer objeto que possua temperatura acima do zero absoluto. As imagens térmicas não são invasivas, não possuem contraindicações e também não causam nenhum desconforto ao paciente, uma vez que a mama no ato do exame estará desnuda e intáctil. Assim sendo, ela possibilita significativas comodidades quando comparada a Mamografia (INFRARED MED, 2017).

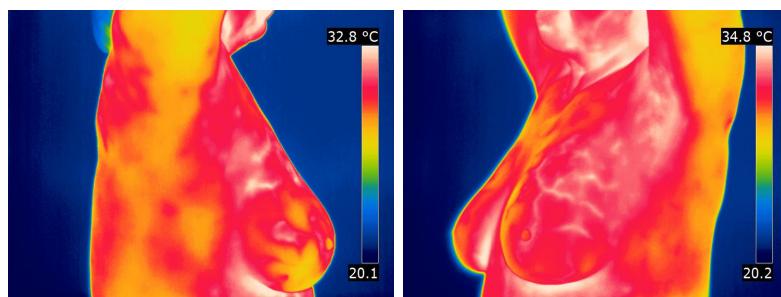


Figura 1: Imagens térmicas utilizadas sob o protocolo estático lateral nos ângulos de 45° e 90°. Fonte: (PROENG, 2012).

Em alguns casos, o câncer de mama pode ocorrer em regiões de difícil acesso, por exemplo, na região lateral das mamas. Neste trabalho serão utilizadas imagens infravermelhas adquiridas sob o protocolo lateral para propiciar um diagnóstico mais completo, principalmente em casos como esse (posição lateral). Assim sendo, o problema descrito nesta monografia é o de obter a região de interesse definida pelas mamas da paciente (segmentação) e classificar essas imagens em anômalas ou não anômalas, especialmente em relação ao diagnóstico de câncer (classificação).

Este trabalho objetiva-se em uma metodologia capaz de segmentar, analisar e classificar imagens infravermelhas das mamas sob o protocolo lateral nos ângulos de 45° e 90° e informar o provável diagnóstico expondo a presença ou não de anomalias, em especial de câncer de mama. As imagens utilizadas pertencem ao Banco de Dados para Pesquisa em Mastologia com Imagem Infravermelha - DMR (PROENG, 2012).

Para o desenvolvimento da metodologia proposta foi realizado um estudo bibliográfico, considerando diferentes métodos de segmentação automática, bem como técnicas de classificação não-supervisionadas. Além disso foram buscadas metodologias existentes

na literatura com o intuito de auxiliar na construção do presente trabalho e para melhor avaliá-lo. Também é realizada uma experimentação e análise de resultados a fim de se verificar se a proposta é promissora para ser usada em situações reais.

A metodologia proposta consiste de duas etapas. A primeira etapa é um algoritmo capaz de segmentar automaticamente as imagens infravermelhas laterais das mamas, utilizando como técnica os descritores advindos dos Histogramas de Gradientes Orientados aplicados a uma Máquina de Vetor Suporte.

A segunda etapa consiste em usar algoritmos semi-supervisionados capazes de realizar a classificação de anomalias em imagens infravermelhas laterais das mamas, utilizando como preceito diversas técnicas de Aprendizado de Máquina (*Machine Learning*), como Máquina de Vetor Suporte (SVM), *Naive Bayes*, K-NN, dentre outros, para verificar qual destes obtém melhores resultados. Busca-se com tal aplicação computacional conceder ao paciente o seu provável diagnóstico, com a presença ou ausência de anomalias nas mamas.

Este trabalho está organizado da seguinte maneira. No Capítulo 2 serão abordados os conceitos fundamentais para o entendimento do método proposto. O Capítulo 3 apresenta os trabalhos que possuem relação com esta obra. O Capítulo 4 descreve o desenvolvimento do método proposto. Os Capítulos 5 e 6, respectivamente, apresentam os resultados obtidos mediante experimentos, conclusões e trabalhos futuros.

## 2 Fundamentação Teórica

Este capítulo possui oito seções. A Seção 2.1 apresenta o câncer de mama em sua magnitude. As metodologias adotadas pela Medicina para a detecção do câncer de mama, por sua vez, estão descritas na Seção 2.2. Uma descrição referente a tecnologia utilizada no trabalho proposto, baseada em imagens infravermelhas, é feita na Seção 2.3. A Seção 2.4 apresenta dois protocolos de aquisição de imagens empregados na literatura científica para a obtenção das supracitadas imagens das mamas. Os conceitos necessários para se compreender a etapa de segmentação das figuras médicas obtidas na seção anterior são retratados a seguir (Seção 2.5). A Seção 2.6 apresenta os métodos baseados em Aprendizado de Máquina para classificação das imagens utilizadas neste trabalho. Finalmente, tem-se as Seções 2.7 e 2.8, respectivamente, descrevendo as métricas utilizadas para validação das imagens e da etapa de classificação.

### 2.1 Câncer de Mama

O câncer de mama é uma doença causada pelo crescimento desordenado de células anormais, tendo como consequência a formação de um tumor. Na maioria dos casos os nódulos formados são benignos e não cancerígenos (malignos) (INCA, 2019b). Os nódulos benignos não se disseminam no tecido mamário e não apresentam grandes riscos à saúde do paciente. Contudo, podem se agravar e aumentar os riscos do desenvolvimento da doença. Os tumores malignos malignas, por sua vez, serão discutidas ao longo desta seção.

#### 2.1.1 Tipos de Câncer de Mama

O câncer de mama pode ser desenvolvido em diferentes regiões das mamas. Os tipos mais comuns são:

##### 2.1.1.1 Carcinoma Ductal *in Situ*

O ducto mamário é o canal responsável pela extração do leite materno. O carcinoma ductal *in situ* é o estágio inicial que afeta este canal. Ele pode estar presente em diferentes regiões da mama, porém não atinge outros tecidos. Contudo, se agravado, pode

tornar-se invasivo. É o tipo mais comum dentre os casos não invasivos, estimado-se 20% dos casos da doença em questão (ONCOGUIA, 2017).

#### 2.1.1.2 Carcinoma Ductal Invasivo

O carcinoma ductal invasivo, em seu estágio avançado, se caracteriza pelo rompimento do ducto mamário e pelo espalhamento das células no tecido adiposo das mamas, podendo ainda atingir outros órgãos através da corrente sanguínea ou sistema linfático. É o tipo mais comum, estimado entre 65% a 85% dos casos malignos (ONCOGUIA, 2017).

#### 2.1.1.3 Carcinoma Lobular *in Situ*

Semelhante ao ductal *in situ*, o carcinoma lobular *in situ* também não atinge outros tecidos e pode ser multifocal, uma vez que a doença acomete mais de uma região da mesma mama. É responsável por atingir os lóbulos mamários, região que produz o leite materno. Estima-se que ocorra em apenas 2% a 6% dos casos (ONCOGUIA, 2017).

#### 2.1.1.4 Carcinoma Lobular Invasivo

Geralmente está associado ao surgimento do câncer no ovário. Esse tipo de câncer possui alta incidência de rompimento dos lóbulos mamários, podendo atingir outros tecidos. Este é o segundo tipo de câncer nas mamas mais frequente, sendo também o mais difícil de diagnosticar (ONCOGUIA, 2017).

#### 2.1.1.5 Doença de Paget

Estimado em 0,5% a 4% dos casos, a doença de Paget se apresenta inicialmente como um câncer no ducto mamário, podendo atingir a pele do mamilo e a aréola. Pode causar inflamações e crostas nos mamilos ou ser assintomático (ONCOGUIA, 2017).

## 2.2 Exames de Diagnóstico por Imagem

O câncer de mama possui diferentes reações e evoluções, portanto fazem-se necessárias diversas metodologias capazes de diagnosticá-la rapidamente para que o paciente possa receber cuidados pré-câncer ou até mesmo começar o tratamento. Os exames mais

utilizados para a detecção da doença são: a Mamografia, a Ultrassonografia e a Ressonância Magnética. A Tabela 1 possui as principais diferenças entre estes métodos.

A ultrassonografia é uma técnica que converte ondas sonoras em imagens. Na maioria dos casos é solicitada quando a mamografia não é suficiente para a realização do diagnóstico ou em casos onde não é possível distinguir o nódulo do cisto (ABRIL, 2018).

A ressonância magnética utiliza ondas de rádio e fortes ímãs para realizar a conversão de ondas sonoras em imagens. Geralmente é indicada para casos onde o paciente tenha próteses ou mamas densas (alto índice de tecido glandular), e para analisar determinados tipos de câncer ou em casos de alto risco (ABRIL, 2018).

De todos os métodos citados para o diagnóstico da doença, a mamografia é o exame mais utilizado pelos médicos para confirmar a presença de nódulos (ABRIL, 2018). O exame consiste na compressão das mamas em um aparelho denominado mamógrafo, que gera uma imagem com a mesma radiação dos raios-X convencionais. Mesmo sendo o mais utilizado, este exame apresenta algumas desvantagens, como o custo financeiro relativamente elevado, ser hostil e agressivo aos pacientes devido a exposição à radiação (ainda que em pouca quantidade), o desconforto ocasionado pelo pressionamento das mamas causado aos pacientes e a imprecisão do diagnóstico em mamas que apresentam uma grande quantidade de tecido glandular, denominadas mamas densas.

## 2.3 Imagens Infravermelhas

Considerando a Lei de Radiação do Corpo Negro que diz que todo corpo emite e absorve radiação (GRIMM, 2019), tem-se que os objetos com temperatura acima de zero absoluto emitem radiação infravermelha que aumenta conforme a temperatura cresce. As câmeras térmicas possuem sensores que permitem essa captura e a conversão desta radiação em imagem. As imagens geradas por estas câmeras são conhecidas como imagens térmicas, ou infravermelhas, e permitem a visualização das regiões com maior concentração de calor.

As imagens térmicas não são invasivas, não emitem radiação ionizante, não dependem de contato físico com o paciente, são indolores e não possuem contraindicações, sendo assim consideradas um método seguro (CÔRTE; HERNANDEZ, 2016). Além disso, possuem como benefício uma análise rápida e eficaz dos resultados advindos dos tratamentos.

Tabela 1: Tabela comparativa dos Exames Médicos por Imagem.

Exames Médicos	Infravermelho	Mamografia	Ultrassonografia	Ressonância Magnética
Tipo	Funcional	Estrutural	Estrutural e Funcional	Estrutural e Funcional
Grau de desconforto	Nenhum	Muito	Muito pouco	Pouco
Funcionamento	Detecta a radiação infravermelha de cada ponto da cena.	Emite radiação ionizante.	Emite e captura ondas de ultrassom.	Gera um campo magnético que atua nos elétrons H <sup>+</sup>
Tipo de desconforto	Mama desnuda	Compressão da mama causando dor	Mama desnuda com gel	Aplicação de contraste
Contra indicação	Não existe.	Não indicado para mama densa.	Dependente do operador.	Possibilidade de alergia ao contraste ou fobia ao clausuramento do aparelho..
Tipo de Imagem	Registra um mapa de temperatura em cada ponto da mama.	Destaca as estruturas e calcificações internas da mama.	Destaca estruturas e fluxos de líquidos.	Destaca estruturas e fluxos de sangue.
Custo	x	100x	100x	800x

Fonte: (RESMINI, 2011), adaptado.

## 2.4 Protocolos de Aquisição

As aquisições das imagens são determinadas por protocolos que podem ser classificados de acordo com a interação realizada com o corpo sob transferência de calor. Estes são divididos em protocolo estático e dinâmico (PROENG, 2012).

### 2.4.1 Aquisição Estática

Na aquisição estática a temperatura do ambiente é controlada e a imagem é capturada no momento em que o paciente está em equilíbrio térmico com o local. Isto faz com que esse protocolo seja eficiente para identificar as regiões de maior concentração de calor nas mamas e possíveis assimetrias no que tange a distribuição de temperatura do paciente. Na Figura 2 é possível visualizar as imagens obtidas neste protocolo.



Figura 2: Imagem térmica frontal das mamas sob aquisição estática. Fonte: (PROENG, 2012).

### 2.4.2 Aquisição Dinâmica

A aquisição dinâmica consiste em uma sequência de fotos capturadas em um intervalo de tempo pré-definido, após uma intervenção que ocasiona influência térmica (resfriamento ou aquecimento) ou química (vasodilatação ou vasoconstrição, dilatação e contração, respectivamente, dos vasos sanguíneos) causada sob a pele do paciente. Este protocolo objetiva analisar a recuperação de temperatura da área analisada sob um período temporal. Na Figura 3 é possível visualizar as imagens geradas pelo protocolo dinâmico.

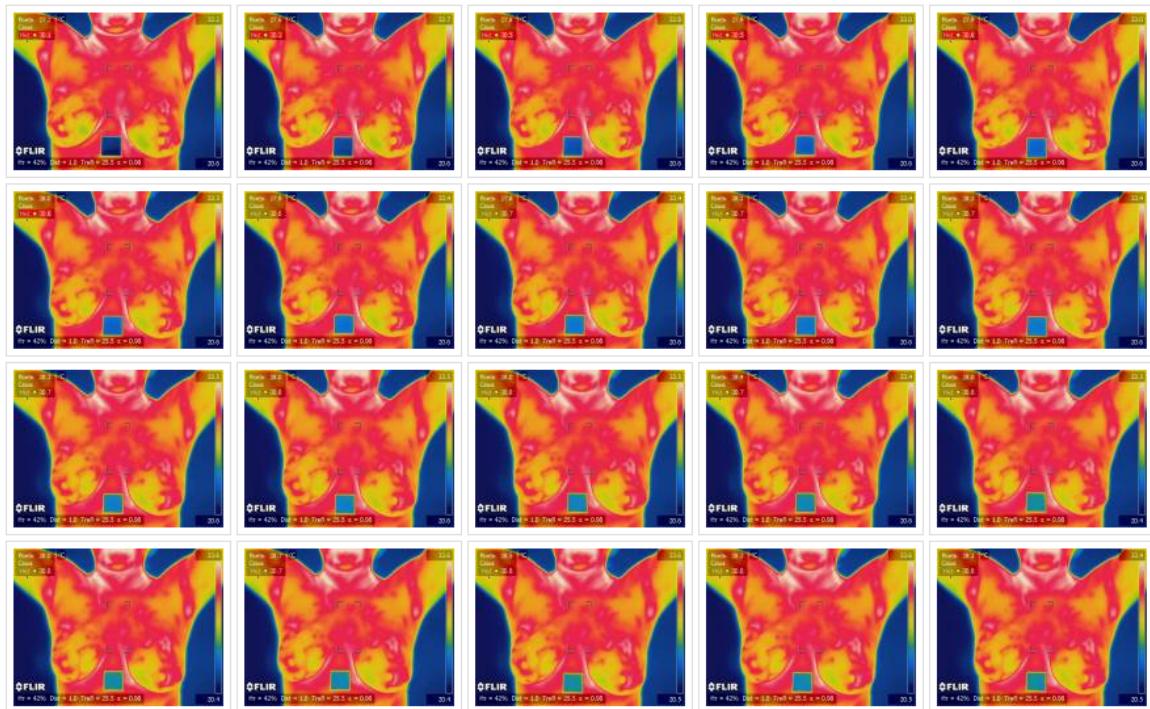


Figura 3: Imagens térmicas frontais das mamas sob aquisição dinâmica. Fonte: (PROENG, 2012).

## 2.5 Segmentação de Imagens

Segmentação na língua portuguesa é o ato de segmentar, dividir, fragmentar algo. Na Visão Computacional, a segmentação de imagens é a divisão de uma imagem em fragmentos com o intuito de simplificar ou modificar a imagem original para facilitar a análise da mesma. A segmentação de imagens é utilizada para identificar ou localizar formas e objetos (DPI/INPE, 2006a).

Segmentação manual ou segmentação padrão consiste no recorte de regiões das imagens realizada por uma pessoa. Esta difere da segmentação automática no sentido que um algoritmo não supervisionado é capaz de extrair essas regiões sem intervenção humana.

A segmentação padrão utilizada neste trabalho consiste na extração manual de fragmentos das regiões das mamas. Esse processo é necessário para o treinamento do algoritmo, tornando-o capaz de distinguir a região mamária para então realizar a segmentação automática.

O segmentador proposto visa a criação de uma base de dados de imagens recortadas para posterior uso. Dessa forma, o classificador poderá se ater apenas às regiões que são relevantes para o diagnóstico das mamas.

Todavia, essas imagens precisam ser validadas para que o segmentador seja eficaz na obtenção da região de interesse e, consequentemente, para a construção de uma base de dados confiável para diagnóstico. Para a validação dessas imagens segmentadas, o presente trabalho realiza uma validação métrica mediante experimentos de comparação pixel a pixel das imagens recortadas pelo algoritmo com as imagens padrão marcadas por humanos. Este processo é descrito na Seção 2.7.

### 2.5.1 Método de Segmentação

A fim de segmentar automaticamente as imagens obtidas da base de dados (PRO-ENG, 2012), foi utilizado o descritor de Histogramas de Gradientes Orientados.

### 2.5.1.1 Histogramas de Gradientes Orientados

O Histograma de Gradientes Orientados (HOG) é um descritor usado para detectar ou reconhecer objetos (DALAL NAVNEET E TRIGGS, 2005). Seu funcionamento consiste em quatro etapas: (i) Computação gradiente; (ii) *Binning* de orientação; (iii) Blocos de descrição; e (iv) Normalização de bloco.

A primeira etapa consiste no cálculo do gradiente da imagem de entrada aplicando o detector de bordas Sobel. Este possui uma máscara cuja direção horizontal é  $[-1, 0, 1]$  e vertical  $[-1, 0, 1]^T$ . No estágio seguinte, subdivide-se a imagem em blocos e calcula-se o histograma da orientação destes gradientes dentro das células de cada bloco.

A terceira etapa realiza a normalização do contraste local, devido a iluminação nas imagens reais. Dessa forma objetiva-se minimizar efeitos luminosos durante o reconhecimento. Essa normalização é realizada através do agrupamento dessas células em blocos maiores (CERNA, 2014). Por fim, a quarta etapa consiste na normalização de todas as células de cada bloco.

No trabalho proposto foram computados os HOG's de cada uma das imagens. Os parâmetros aplicados foram: oito histogramas de orientação dos gradientes, grades de células da ordem de 16x16 pixels, 4x4 células por bloco e, finalmente, os blocos foram normalizados usando a norma L2.

Dado que  $v$  representa o vetor de características não normalizado, o fator de normalização ( $L2$ ) pode ser descrito como mostra a Equação 2.1.

$$L2 = \frac{v}{\sqrt{\|v\|_2^2 + e^2}} \quad (2.1)$$

## 2.6 Classificação de Imagens

Classificação de Imagens é o processo de rotular as imagens em classes (ou grupos) de acordo com as suas características ou atributos. Define-se um conjunto de entrada  $X$  (que neste contexto pode ser uma ou mais imagens) e um conjunto de rótulos  $R$  (características específicas, que podem ser classificadas, por exemplo, em anômalas ou não anômalas) para a classificação. Para cada entrada  $x \in X$  vincula-se um rótulo  $r \in R$ . Para  $X$  tem-se  $X_{treino}$  e  $X_{teste}$  que, respectivamente, são as imagens empregadas nos conjuntos de treino e teste do método de classificação  $C$  (DPI/INPE, 2006b).

Em seguida, cria-se uma base de treinamento  $T$  composta por imagens de  $X_{treino}$ . As amostras  $x_{tr}$  pertencentes a  $X_{treino}$  são usadas para treinar  $C$ , de forma que este seja usado para decidir o rótulo de cada  $x_{te} \in X_{teste}$ . Cada  $x_{tr}$  possui rótulos por definição informados de maneira supervisionada, enquanto cada  $x_{te}$  terá seus rótulos definidos por  $C$ .

## 2.6.1 Métodos de Classificação

O presente trabalho também objetiva obter o rótulo que melhor é vinculado com cada amostra  $x_{te}$ , ou seja, saber a qual classe (saudável ou não) cada imagem pertence. Para esta etapa foram testados seis métodos distintos para se fazer esta classificação, sendo eles: Máquina de Vetor Suporte, Regressão Logística, *Naive Bayes*, Árvore de Decisão, Floresta Randômica e *K-Nearest Neighbors*.

### 2.6.1.1 Máquinas de Vetores Suporte

O método de Máquinas de Vetores Suporte (*Support Vector Machines* - SVM) é descrito por um algoritmo de aprendizado supervisionado, em que as amostras oriundas de  $X_{te}$  podem ter seus rótulos atribuídos com acurácia. Este método faz uso de descritores contidos nas imagens  $X_{tr}$  definidas na base de dados  $T$  para classificações futuras.

O SVM prescinde do conceito de hiperplanos que definem limites de decisão. Um hiperplano é uma definição geométrica que partitiona um conjunto de amostras com características semelhantes entre si e que estão dispostos em uma região espacial. O hiperplano realiza a separação destes objetos em subespaços distintos que, por sua vez, definem classes ou rótulos (PORTELA FERNANDA AMORIM, 2017).

As amostras representadas na Figura 4 estão particionadas em um espaço bidimensional, de forma que o hiperplano é representado por uma reta que consegue separá-las em dois conjuntos (rótulos) distintos. Para esta segmentação, foi empregada como característica separatória, a distinção geométrica das amostras (estrelas ou circunferências). Este exemplo também é conhecido como classificação linear (STATSOFT, 2019).

No entanto, em muitos casos, o conjunto amostral não é linearmente separável. Ainda assim, o SVM pode ser aplicado para espaços de maior dimensionalidade. Nesta situação projeta-se os dados do espaço não linearmente separável para um espaço com

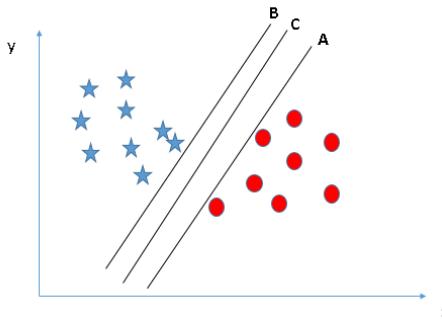
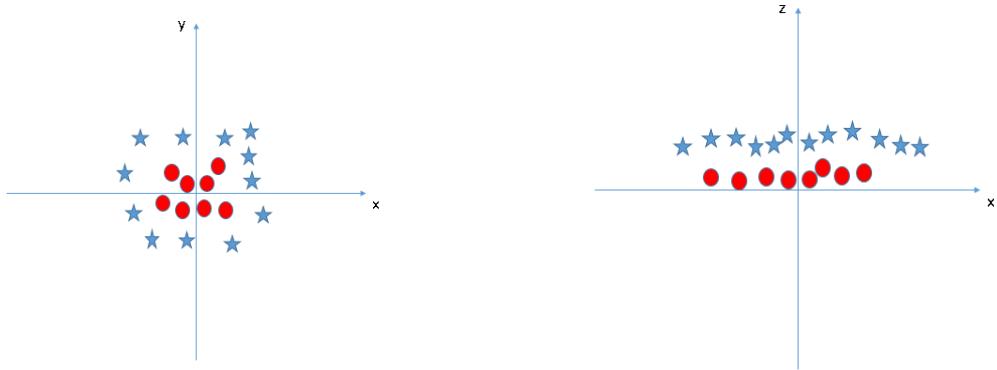


Figura 4: Classificação Linear do SVM. Fonte: (SOUZA, 2019).

dimensão superior, que permite separá-los linearmente.

A Figura 5(a) descreve dois tipos de amostras (estrelas e circunferências) representadas em  $\mathbb{R}^2$  e que não são linearmente separáveis. Com o intuito de partitioná-los de forma linear, uma possível solução seria elevar o plano  $\mathbb{R}^2$  para  $\mathbb{R}^3$ , como mostra a Figura 5(a), recuperando sua ordem linear sob uma dimensão acima.

(a) Objetos representados no plano  $\mathbb{R}^2$ . (b) Objetos representados no plano  $\mathbb{R}^3$ .Figura 5: Problema linearmente separável em dimensão  $\mathbb{R}^3$ . Fonte: (SOUZA, 2019).

O método SVM permite a classificação de amostras  $x_{te}$  de entrada (etapa de teste) baseado nas amostras  $x_{tr}$  oriundas da base de dados  $T$  (etapa de treinamento). O estágio de treinamento objetiva construir um modelo capaz de discernir os elementos  $x_{te}$  em hiperplanos, ou seja, criar classes (rótulos) divergentes compostas por amostras homogêneas.

Na etapa de teste, por sua vez, busca-se classificar cada amostra  $x_{te}$  se esta representa uma imagem mamária anômala ou não anômala.

### 2.6.1.2 Regressão Logística

A regressão logística consiste em um modelo estatístico que visa descrever a probabilidade de uma amostra pertencer a uma classe ou de um evento ocorrer. Esse modelo é utilizado para analisar uma ou mais variáveis independentes, sendo estas preditivas ou explicativas, mas capazes de determinar um resultado. Esse resultado, também conhecido como variável dependente, deve ser dicotômica ou binária, ou seja, a resposta é representada como um par ordenado: (Sim, Não), (Positivo, Negativo) (MEDCALC, 2019).

Ao analisar um conjunto de dados, o método procura construir um modelo capaz de descrever a relação dessas variáveis independentes, e por fim, elaborar uma fórmula que poderá calcular a probabilidade da variável dependente possuir um determinado rótulo ou de um evento ser disparado. Esta fórmula pode ser expressa como determinada na Equação 2.2, em que  $p$  é a probabilidade da presença da característica de interesse.

$$\text{logit}(p) = \frac{p}{1-p} \quad (2.2)$$

Existem três tipos de modelos de regressão logística. O mais popular é o de *regressão logística binária*, que apresenta apenas dois rótulos de saídas possíveis, por exemplo: Sim ou Não, Saudável ou Doente; diferente do modelo binário, a *regressão logística multinomial* é empregada quando a variável dependente possui três ou mais rótulos possíveis, como: Saudável, Curado e Doente; finalmente, a *regressão logística ordinal*, assim como a multinomial, também descreve o resultado em três ou mais categorias, porém de forma ordenada, como: Baixo, Médio e Alto.

### 2.6.1.3 Naive Bayes

A família de métodos *Naive Bayes* consiste em um conjunto de algoritmos de inferência probabilística baseados no Teorema de Bayes (MASTERY, 2016). Este, por sua vez, prevê as chances de um evento ocorrer baseado em outro evento que ocorreu antes (PHILOSOPHY, 2003). Estes supõem que todos os atributos que influenciam na rotulação de um modelo são independentes, ou seja, a presença (ou ausência) de uma característica de uma classe não possui relação com a presença (ou ausência) de outra característica.

Para melhor compreensão, considere um exemplo didático. Para que a fruta maçã seja identificada como tal, três atributos de seus descritores são analisados: sua cor deve

ser vermelha, seu formato deve ser arredondado e seu tamanho deve possuir em torno de 10 centímetros. O Teorema de Bayes determina que cada uma dessas características, individualmente, contribuem para que a classificação de uma nova fruta seja uma maçã, mesmo que elas dependam da existência de outras características. Devido a este comportamento limitante, os modelos baseados em *Naive Bayes* são tratados como "ingênuos".

O Teorema de Bayes prediz a probabilidade de um evento ocorrer, dado a probabilidade de outro evento que já ocorreu. Matematicamente, o teorema é expresso como mostra a Equação 2.3:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)} \quad (2.3)$$

Considerando que o evento  $A$  é a hipótese e o evento  $B$  é uma evidência, tem-se:

- $P(A|B)$ : Probabilidade de  $A$  ocorrer dado que o evento  $B$  já ocorreu.
- $P(B|A)$ : Probabilidade do evento  $B$  ocorrer, dado que a hipótese  $A$  é verdadeira.
- $P(A)$ : Probabilidade de  $A$  ocorrer.
- $P(B)$ : Probabilidade de  $B$  ocorrer.

#### 2.6.1.4 Árvore de Decisão

Metodologias baseadas em Árvore de Decisão são construídas visualmente no formato de fluxograma, representação esquemática de um algoritmo, que mapeia os possíveis caminhos e decisões a serem tomadas sobre um contexto. Geralmente é criada por um único nó que, por sua vez, se divide em duas ou mais possibilidades, as quais podem se ramificar em outras probabilidades. Isso ocorre até o momento que um nó do último nível é atingido, que define o rótulo ou classe final para aquela amostra.

Esse tipo de fluxograma possui três elementos, mais conhecidos como nós, para sua criação: nós de decisão, nós de probabilidade e nós de término. Para a compreensão do método, considere a representação visual (Figura 2.6.1.4). Os nós de decisão definem uma possível escolha e são representados por um quadrado na figura. Os nós de probabilidade, esquematizados por um círculo, apresentam possíveis probabilidades de uma decisão tomada ser correta. Os nós de término, também conhecidos como nós de desfecho ou nós folha, são representados por um triângulo equilátero e definem a saída do modelo.

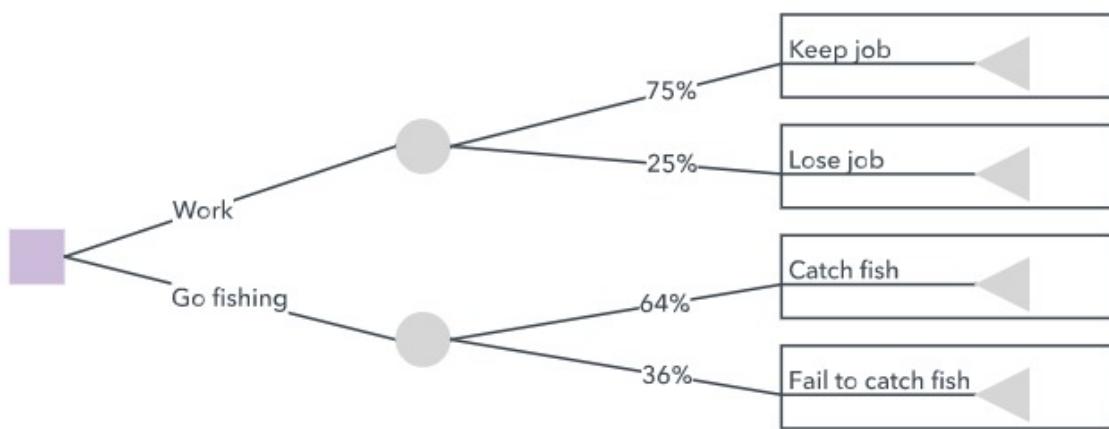


Figura 6: Exemplo de uma Árvore de Decisão para uma situação fictícia. Fonte: (LUCIDCHART, 2019).

A fim de exemplificar esse método, continue observando a árvore de decisão definida na Figura 2.6.1.4. Inicialmente, o ramo da árvore selecionado a partir do primeiro nível é “Ir trabalhar” (*Work*) ou “Ir pescar” (*Go fishing*). Se for tomada a decisão de ir trabalhar, a probabilidade de se manter o emprego (*Keep job*) será então de 75%. Contudo, a probabilidade de perdê-lo (*Lose job*) é de 25%. Por outro lado, se a decisão definida for de ir pescar, as chances de se pescar um peixe (*Catch fish*) serão de 64%, enquanto as chances de falhar ao realizar a pesca (*Fail to catch fish*) serão de 36%.

#### 2.6.1.5 Floresta Randômica

O método de Floresta Randômica, também conhecido como Floresta Aleatória, é um algoritmo de aprendizado supervisionado. Neste modelo, o rótulo com o maior número de previsões, advindas de diversas árvores de decisão geradas, com conjuntos de treino distintos, se torna a previsão do modelo. Uma grande vantagem desse algoritmo é a baixa correlação entre as árvores construídas, algo que eleva a precisão do modelo ao ponto de prever com maior acurácia do que uma árvore de decisão individual.

Essa baixa correlação entre os modelos ocorre devido ao conceito de *Bagging*, também conhecido como Agregação de *Bootstrap*, e que é responsável pela combinação das árvores a fim de se reduzir a variação do modelo, sem aumentar o viés inicial. Ele busca pela melhor característica, de forma aleatória, para a criação destas árvores. Este processo, também conhecido como ensacamento, gera as mais diversas combinações acarretando em uma acurácia mais elevada.

As árvores de decisão com níveis muito profundos sofrem de um grande problema de Aprendizado de Máquina, o *overfitting* (sobreajuste). Este ocorre quando o modelo se ajusta de maneira exagerada ao conjunto amostral usado no treino. Ainda assim, é um problema minimizado ao se usar as Florestas Aleatórias, uma vez que elas são compostas das mais diversas combinações em sua estrutura. Apesar de apresentar uma computação mais lenta, o mesmo traz um resultado mais preciso.

#### 2.6.1.6 K-Nearest Neighbors

O *K-Nearest Neighbors* (KNN) é um algoritmo de aprendizado de máquina supervisionado baseado em analogia. Dado um elemento de entrada (desconhecido), o algoritmo busca por  $K$  elementos que o cercam, também conhecido como  $K$ -vizinhos, que possuem a menor distância dentro de um determinado raio. O rótulo (classe) mais frequente nesse raio será o rótulo atribuído a esse elemento de entrada (SCIENCE, 2018).

Para o cálculo dessa distância entre o elemento desconhecido e os demais, o algoritmo utiliza algumas métricas capazes de encontrar a menor distância entre dois pontos. A métrica utilizada neste trabalho é a distância Euclidiana, que pode ser calculada através da Equação 2.4, dado que  $x$  e  $y$  são dois pontos pertencentes a  $\mathbb{R}^2$ .

$$d(x, y) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \dots + (x_n - y_n)^2} \quad (2.4)$$

A Figura 7 apresenta dois tipos de objetos (classes), o quadrado azul (QA) e o triângulo vermelho (TV). O objetivo é classificar, ou seja, associar o elemento desconhecido (Circunferência verde - CV) a uma das classes.

Inicialmente, foi obtido um conjunto de três elementos, delimitados pelo segmento contínuo interior, sendo dois TV e um QA. Neste caso, o algoritmo classificaria o elemento desconhecido como TV, pois foi a classe com maior incidência ao redor do raio. Contudo, ao aumentar o valor deste raio, delimitado pela linha seccionada, o algoritmo obteve cinco elementos, sendo três QA e dois TV. Neste caso, o rótulo associado ao elemento desconhecido seria QA.

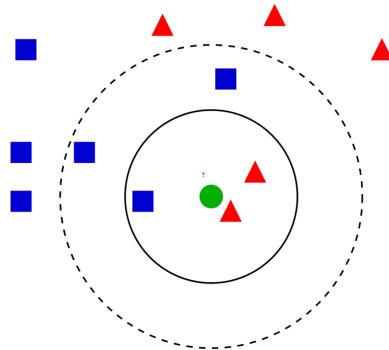


Figura 7: Classificação de um elemento desconhecido através da análise dos K-vizinhos. Fonte: (VIDHYA, 2018).

## 2.7 Métricas de Acurácia para Segmentação de Imagens

A fim de se definir quais são os melhores algoritmos a serem usados para a segmentação da região de interesse mamária, esse trabalho realiza uma avaliação quantitativa. Isto será feito mediante comparação pixel a pixel das imagens segmentadas pelo algoritmo descrito na Seção 2.5 com as mesmas imagens do conjunto da segmentação padrão. As imagens  $x_i$  serão particionadas em dois subconjuntos, tais que  $x_i = o_i \cup f_i$ . A partição  $o_i$  descreve a parte da imagem  $x_i$  composta pela região de interesse(mamas), enquanto  $f_i$  delimita a área de  $x_i$  em que os pixels não pertencem ao segmento mamário.

Se o pixel  $p_i(x, y)$  pertencer a  $o_i$ , ele é classificado como positivo. Caso  $p_i(x, y) \notin o_i$ , ele é classificado como negativo. Assim, tem-se os seguintes rótulos para cada pixel  $p_i(x, y) \in x_i$ :

- $p_i(x, y)$  é *Verdadeiro Positivo (VP)* quando este é classificado como positivo tanto na imagem  $x_i$  do conjunto padrão quanto pela segmentação automática efetuada por um algoritmo.
- $p_i(x, y)$  é *Verdadeiro Negativo (VN)* quando o pixel é rotulado como negativo tanto em  $x_i$  no conjunto manual quanto pela mesma imagem oriunda da segmentação automática.
- $p_i(x, y)$  é *Falso Positivo (FP)* nas situações em que o pixel é classificado como positivo pela segmentação automática de  $x_i$  e negativo pela segmentação manual em  $x_i$ .
- $p_i(x, y)$  é *Falso Negativo (FN)* nas situações em que o pixel é classificado como

negativo pela segmentação automática de  $x_i$  e positivo pela segmentação manual em  $x_i$ .

## 2.8 Medidas Estatísticas para Segmentação de Imagens

As medidas estatísticas são utilizadas para aferir quantitativamente os resultados obtidos pelo método de segmentação descrito na Seção 2.5, sendo elas: a acurácia, a sensibilidade, a especificidade, a preditividade positiva e a preditividade negativa. Cada uma destas medidas serão descritas a seguir.

- A Acurácia ( $ACC$ ) representa a taxa de acertos que o método obteve para segmentar a imagem  $x_i$ , ou seja, a precisão ao rotular os pixels da imagem tanto no conjunto padrão quanto na segmentação automática (Equação 2.5).

$$ACC = \frac{VP + VN}{VP + VN + FP + FN} \quad (2.5)$$

- A Sensibilidade ( $SEN$ ) descreve a qualidade do segmentador em identificar os pixels pertencentes a região de interesse  $o_i$  (Equação 2.6).

$$SEN = \frac{VP}{VP + FN} \quad (2.6)$$

- A Especificidade ( $ESP$ ) representa a qualidade do método de segmentação em especificar os pixels  $p_i(x, y) \in f_i$ , ou seja, não pertencentes à ROI (Equação 2.7).

$$ESP = \frac{VN}{VN + FP} \quad (2.7)$$

- A Preditividade Positiva ( $PDP$ ) é a taxa de acertos positivos dentre todas as classificações positivas. (Equação 2.8).

$$PDP = \frac{VP}{VP + FP} \quad (2.8)$$

- A Preditividade Negativa ( $PNP$ ) é a taxa de acertos negativos dentre todas as classificações negativas. (Equação 2.9).

$$PNP = \frac{VN}{VN + FN} \quad (2.9)$$

## 2.9 Medidas Estatísticas para Classificação de Imagens

As medidas exemplificadas anteriormente (Seção 2.8) também podem ser adotadas para modelos de classificação. Entretanto, por ser mais convencional utilizar apenas as métricas de acurácia, sensibilidade e especificidade em trabalhos de diagnóstico de anomalias em câncer de mama (classificação), o presente trabalho faz uso apenas dessa medida no Capítulo 5.

- A Acurácia (*ACC*) representa a taxa de acertos que o método obteve em associar os rótulos (doente e saudável) a cada uma das imagens do conjunto (Equação 2.10).

$$ACC = \frac{VP + VN}{VP + VN + FP + FN} \quad (2.10)$$

- A Sensibilidade (*SEN*) descreve a qualidade do classificador em especificar as imagens que possuem o rótulo de doente vinculado (Equação 2.11).

$$SEN = \frac{VP}{VP + FN} \quad (2.11)$$

- A Especificidade (*ESP*) descreve a qualidade do classificador em identificar as imagens que possuem o rótulo de saudável vinculado (Equação 2.12).

$$ESP = \frac{VN}{VN + FP} \quad (2.12)$$

# 3 Trabalhos Relacionados

A classificação de imagens médicas exige conhecimento prévio para a identificação de potenciais anormalidades. Contudo, é possível que o computador, através de um algoritmo de aprendizado de máquina eficaz, auxilie os médicos a realizar esta tarefa, dado um bom conjunto de dados.

Neste capítulo serão apresentados alguns trabalhos propostos na literatura que serão utilizados como referência para a metodologia proposta, com o intuito de estudar os métodos apresentados e analisar os resultados obtidos por cada autor.

## 3.1 (OLIVEIRA, 2012)

O trabalho proposto por (OLIVEIRA, 2012) consiste em uma metodologia capaz de realizar a segmentação automática de imagens infravermelhas laterais das mamas provenientes de bases de dados. O método identifica a prega inframamária (junção da parte inferior da mama com a parede anterior do tórax) automaticamente e realiza a segmentação a partir da mesma.

São utilizadas pelo autor um total de 328 imagens no ângulo de 90° (câmera frontal) advindas de duas bases de dados. Estas imagens são manipuladas por uma etapa de pré-processamento cujo objetivo é a transformação das imagens térmicas originais em tons de cinza no formato *bitmap*, como mostra a Figura 3.1

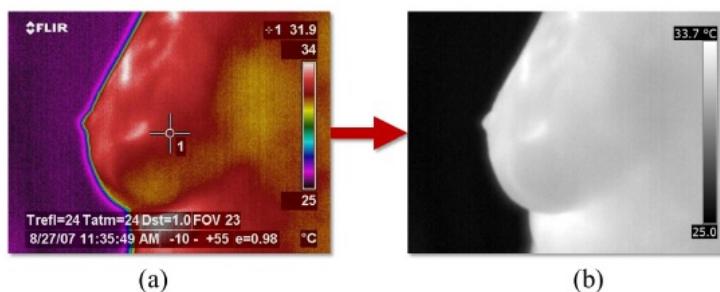


Figura 8: Imagem térmica lateral esquerda da mama no ângulo de 90°. (a) Imagem original advinda da base de dados. (b) Imagem convertida em escala de cinza. Fonte: (OLIVEIRA, 2012).

O processo de segmentação automática das imagens é dividido em cinco etapas. A

primeira delas é a limiarização da imagem, em que é realizada a conversão das imagens em tons de cinza para preto e branco através de um balanceamento nos histogramas de cada imagem. A segunda etapa consiste na remoção de itens indesejáveis do fundo de cada cena advindas do processo da captura das imagens dos pacientes. Esta etapa utiliza a clusterização baseada na divisão dos pontos das imagens em grupos de acordo com sua vizinhança.

O processo de obtenção da região de interesse consiste em três etapas. A primeira delas é a detecção de cantos que se baseia na identificação da extremidade da mama. Com isso, o método delimita a região de interesse (as mamas). A etapa seguinte utiliza o algoritmo *Shi-Tomasi Corner Detector* (2013) que aprimora o refinamento dos cantos obtidos na etapa anterior. Após esse refinamento, o método identifica a prega inframamária e a região areolar das imagens.

Com a região de interesse delimitada, a segmentação automática é realizada. Esta etapa consiste em selecionar um ponto em que se localiza a prega inframamária e traçar uma reta horizontal em direção à margem da imagem. A Figura 9 apresenta a aplicação de cada uma das etapas realizadas pelo autor.

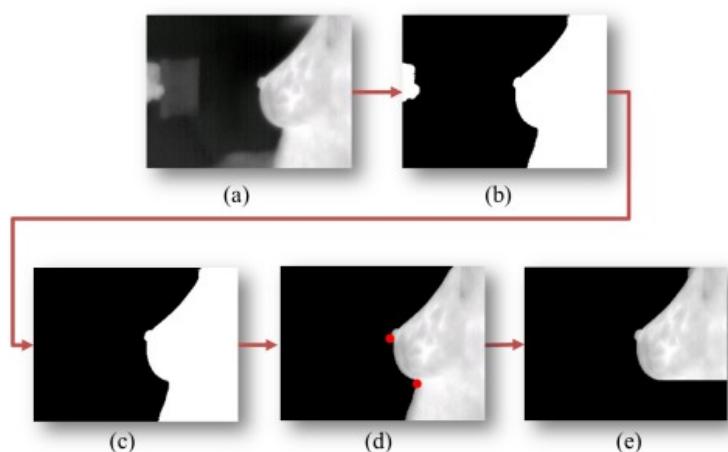


Figura 9: Etapas do Método de Segmentação de Oliveira: (a) Imagem térmica em escala de cinza. (b) Limiarização. (c) Remoção de elementos indesejáveis. (d) Detecção e refinamento de cantos. (e) Segmentação final. Fonte: (OLIVEIRA, 2012).

Para a etapa de segmentação das imagens da base de dados (PROENG, 2012), foi obtida uma acurácia de 93%, sensibilidade de 95%, especificidade de 96%, preditividade positiva a 96% e preditividade negativa a 96%. Com isso, o método abordado por (OLIVEIRA, 2012) se mostra bastante eficiente ao segmentar as imagens infravermelhas

laterais das mamas.

### 3.2 (FRANCIS; SASIKALA; SARANYA, 2014)

O trabalho proposto pelos autores objetiva realizar a segmentação e classificação de imagens infravermelhas laterais das mamas em anômalas e não anômalas, usando extração de recursos com base na transformação *Curvelet* (CANDES EMMANUEL E DEMANET, 2006), introduzidos a seguir em uma Máquina de Vetor Suporte.

Para a obtenção das imagens, foram realizadas uma série de restrições, como: o controle da temperatura da sala em 25°, a proteção das janelas da sala com o intuito de evitar interferências, a solicitação aos pacientes de que não fumassem duas horas antes da captura da imagem e que não realizassem o uso de creme, loção ou desodorante. As imagens pertencem a vinte e dois pacientes, sendo onze saudáveis e onze não saudáveis e foram registradas em três posições: frontal, oblíqua e lateral.

O processo da obtenção do diagnóstico possui três etapas. A primeira etapa é a segmentação da região anormal (Figura 10), que é dividida em seis subetapas. Inicialmente realiza-se a conversão das imagens em escalas de cinza. Em seguida, é feita uma melhoria no contraste destas imagens. A terceira etapa consiste em retirar as regiões com alta concentração de calor, como pescoço, axilas entre outros. Posteriormente, é utilizado o algoritmo de *Sobel Edge* para a detecção de cantos e bordas de fundo. Na quinta etapa são realizadas algumas operações morfológicas para a segmentação da região anormal. Na sexta e última etapa, ocorre uma comparação da região segmentada com a região contida na imagem original, a fim de se observar variações de intensidade de calor.



Figura 10: Obtenção da região anormal das mamas. Fonte: (FRANCIS; SASIKALA; SARANYA, 2014).

A segunda etapa extrai informações das imagens normais e anormais através da transformação de *Curvelet* (CANDES EMMANUEL E DEMANET, 2006), técnica que

permite a representação de um objeto em diversas escalas. Por fim, a terceira etapa é o processo de classificação. As informações extraídas de *Curvelet* das imagens saudáveis e doentes são submetidas ao algoritmo de classificação SVM (Seção 2.6.1.1).

Para o método proposto, os autores utilizaram vinte e duas imagens, sendo onze de pacientes saudáveis e onze de pacientes doentes. Como resultado, os autores obtiveram 90,91% de acurácia, 81,82% de sensibilidade e 100% de especificidade.

### 3.3 (BAFFA; LATTARI, 2018)

O trabalho proposto por Baffa e Lattari (2018) opta por realizar a classificação de imagens infravermelhas frontais das mamas em anômalas e não anômalas, considerando protocolos distintos, através de Redes Neurais Convolucionais, método que pouco havia sido empregado em trabalhos que lidam com problemas similares. Como resultado de seus trabalhos, os autores obtiveram 98% de acurácia para o protocolo estático e 95% para o protocolo dinâmico.

As imagens infravermelhas utilizadas no trabalho de Baffa e Lattari seguem os protocolos abordados na Seção 2.4 e pertencem ao Banco de Dados para Pesquisa em Mastologia com Imagem Infravermelha (PROENG, 2012).

As imagens do protocolo estático do DMR totalizam 177 imagens de pacientes saudáveis e 42 de pacientes não saudáveis. Já no protocolo dinâmico, cada paciente possui um conjunto de 20 imagens, sendo assim, dos 95 pacientes saudáveis, totalizam-se 1900 imagens. No caso dos pacientes com câncer de mama, são 880 imagens advindas de 42 pacientes.

A fim de se classificar as imagens, os autores utilizaram como metodologia algorítmica, para solucionar o problema de diagnóstico, a estratégia de Redes Neurais Convolucionais (CNN), que consistem em 3 etapas: (i) Extração de Características, fase em que se abstrai pixels críticos da imagem a fim de se identificar padrões locais; (ii) Mapeamento de Características, em que cada camada da rede neural possui um conjunto de mapas de características responsáveis por refinar os descritores, assim apenas os padrões de maior relevância serão considerados; e (iii) Subamostragem, que consiste em selecionar amostras de cada mapa de característica. Essas amostragens podem ser encontradas ao calcular a média, soma ou ao selecionar o maior ou menor valor da região analisada.

Para o protocolo estático, a rede CNN classifica as imagens de cada paciente utilizando validação cruzada (*Cross-Validation*). A ideia dessa validação é medir a acurácia do modelo múltiplas vezes, sem que amostras da base de treino interfiram no conjunto de teste.

Além disso, a metodologia de Baffa e Lattari se diferencia de outras apresentadas anteriormente, uma vez que a CNN é responsável por identificar padrões e características de cada imagem analisada, portanto não é necessário informar manualmente tais informações.

Para o protocolo dinâmico, quatro estratégias foram descritas com o intuito de identificar aquela que apresente uma melhor acurácia. A primeira delas consiste em um vetor que armazena as 20 imagens dos pacientes, tratando-as como partes de uma única imagem, como mostra a Figura 11.

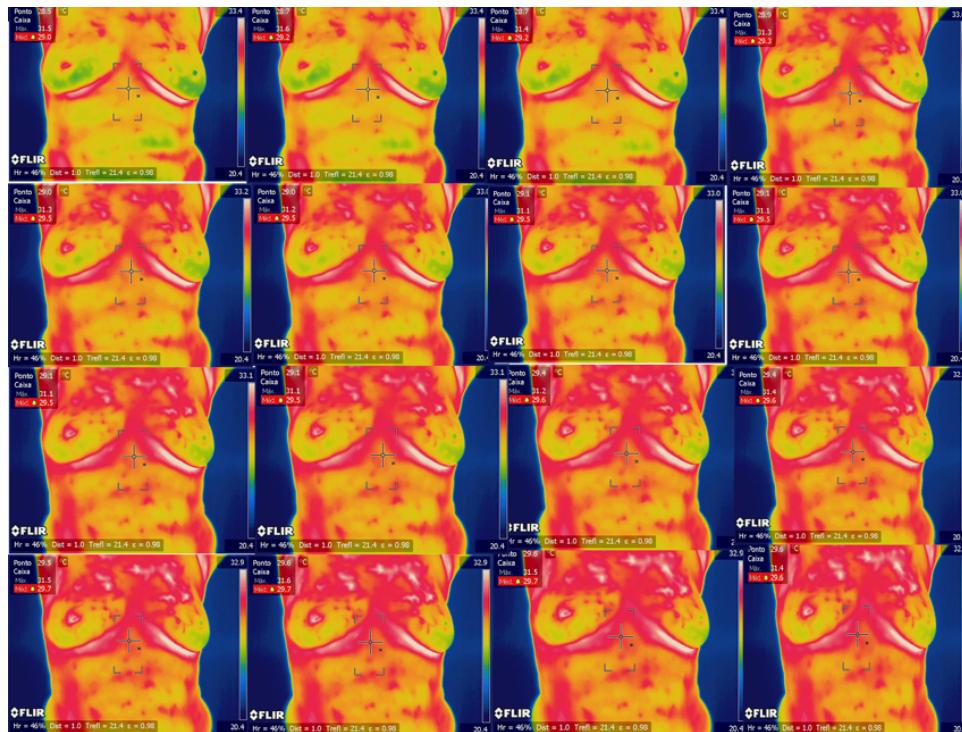


Figura 11: Imagens infravermelhas frontais sob o protocolo dinâmico. Fonte: (PROENG, 2012) apud (BAFFA; LATTARI, 2018).

A segunda estratégia consiste em calcular a média das 20 imagens de cada paciente, resultando assim em uma única figura que será utilizada para a classificação.

A terceira estratégia adotada pelos autores consiste em examinar as duas imagens que, em teoria, apresentam maior divergência de temperatura, que são a primeira e a

última imagem dessa coleção. Com isso, é computada a média de ambas gerando uma única imagem que será utilizada para o treinamento do modelo.

A quarta e última estratégia realiza a subtração da última imagem com a primeira, gerando uma imagem que será usada pela rede neural.

Independente do protocolo de aquisição utilizado, a metodologia de classificação baseia-se nas etapas de treinamento e teste. A fase de treinamento tem o intuito de modelar a CNN, enquanto a fase de teste tem como finalidade analisar esse modelo e fornecer sua acurácia. Assim, verifica-se se é factível usar a proposta em casos reais.

O protocolo estático é composto por 300 imagens, das quais 10% foram utilizadas na fase de testes e 90% no treinamento da CNN. Já a aquisição dinâmica utiliza 88% das imagens na fase de treinamento e 12% na fase de testes. A metodologia é composta por 10 experimentos, com o intuito de utilizar todas as imagens da base, alternando suas utilizações nos dois conjuntos por conta do uso da validação cruzada.

Para a aquisição estática foram usadas 300 imagens, sendo 126 de pacientes não saudáveis e 174 de pessoas saudáveis. Nesse experimento, os autores obtiveram 98% de acurácia utilizando imagens coloridas, uma vez que estas imagens retratam mais fidedignamente as informações sobre a temperatura, e 95% de acurácia utilizando imagens em escala de cinza. Já para a aquisição dinâmica com 137 pacientes, das quais cada pessoa possui 20 imagens, resultou-se em 95% de precisão para imagens coloridas e 92% para figuras em tons de cinza.

### 3.4 (LESSA; MARENCONI, 2016)

O método proposto por Lessa e Marengoni (2016) realiza a classificação de imagens infravermelhas considerando oito medidas estatísticas, sendo elas: média, variância, desvio padrão (SD), assimetria, curtose, entropia, amplitude e mediana. Para a classificação de fato, usa-se uma Rede Neural Artificial (RNA).

Para o método proposto, os autores selecionaram 97 imagens aleatórias da base de dados DMR, sendo 48 de mamas saudáveis e 46 de não saudáveis, pertencentes a 47 pacientes.

O método utilizado consiste em uma avaliação quantitativa de temperatura para

cada paciente, sendo este subdividido em 4 etapas: (i) Pré-processamento, responsável pela remoção das regiões que não são relevantes, remoção do fundo e transformação da imagem para uma escala de cinza; (ii) Segmentação, que secciona a região de interesse (ROI) e separa a região da mama direita da esquerda; (iii) Extração de Características, que analisa a assimetria das temperaturas nas mamas através das medidas estatísticas; (iv) Classificação, que faz uso de uma RNA para identificar os padrões e classificá-los. Nessa etapa, os autores compararam dois modelos de redes neurais, a primeira utiliza apenas uma camada intermediária, ou seja, é capaz de resolver um problema linearmente separável, diferente da segunda RNA que é destinada a problemas não-lineares.

Para a realização da classificação, 25 imagens de pacientes saudáveis e 25 de pacientes não saudáveis são selecionadas aleatoriamente para o treinamento da RNA. O método faz uso do algoritmo *backpropagation*, capaz de atualizar eficientemente os pesos dos neurônios atribuídos à rede neural.

Para a classificação utilizando o modelo linear, o treinamento foi considerado satisfatório quando atingiu a taxa de erro igual a 0.205. O modelo não linear, por sua vez, obteve uma taxa de erro igual a 0.016.

Para o modelo não linear obteve-se 85% de acurácia, 87% de sensibilidade e 83% de especificidade, enquanto o modelo linear apresentou 63% de precisão, 57% de sensibilidade e 69% de especificidade. O modelo não-linear resultou em uma melhor classificação para as imagens, comparado ao modelo linear.

# 4 Metodologia

## 4.1 Algoritmo Proposto

Para o método proposto fazem-se necessárias três etapas a fim de se obter o diagnóstico. A Seção 4.1.1 apresenta a primeira fase responsável pela obtenção das imagens. A Seção 4.1.2 retrata o processo de segmentação das imagens adquiridas na seção anterior. Por fim, a Seção 4.1.3 descreve a etapa de classificação destas imagens (Aprendizado de Máquina) e, consequentemente, o diagnóstico do paciente.

### 4.1.1 Obtenção das Imagens

A primeira etapa consiste no processo de obtenção das imagens dos pacientes. Neste trabalho foram utilizadas as imagens de uma base de dados pública denominada *Database for Mastology Research* (DMR) (PROENG, 2012), advinda de pesquisadores da Universidade Federal Fluminense (UFF).

A DMR possui imagens contemplando os protocolos dinâmico e estático. O que os diferenciam é a metodologia de captura das imagens e na quantidade de imagens geradas para cada paciente (Seção 2.4). Para o presente trabalho serão utilizadas apenas as imagens sob o protocolo estático nos ângulos de 45° e 90°. A Figura 12 retrata algumas imagens utilizadas neste trabalho.

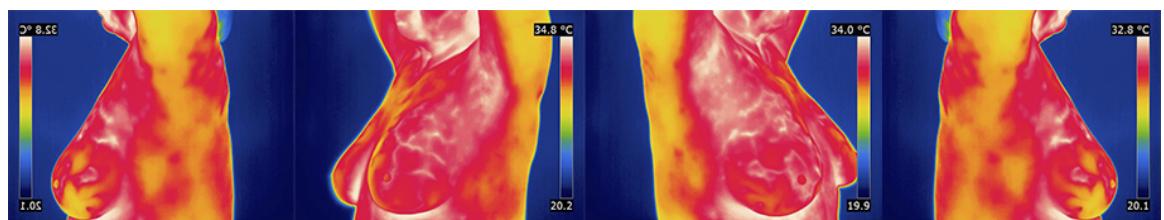


Figura 12: Imagens infravermelhas laterais das mamas no ângulos de 45° e 90°. Fonte: (PROENG, 2012) apud (BAFFA; LATTARI, 2018).

Foram utilizadas 683 imagens de pacientes saudáveis, nos ângulos de 45° e 90° das mamas esquerda e direita. Além destas, também foram utilizadas 166 imagens de pacientes doentes nos ângulos de 45° e 90°, sendo 83 de pertencentes a mama esquerda e

83 da mama direita. As imagens possuem, como dimensão espacial, 640 pixels de largura e 480 pixels de altura, armazenadas no formato *Joint Photographic Experts Group* (JPG).

As imagens obtidas através da base DMR são baixadas no formato .JPG em escalas de cinza (Figura 13) e são separadas em dois grupos *neg* e *pos*. O grupo *neg* (abreviação de negativo) são as imagens de pacientes que, segundo o algoritmo, não possuem o câncer de mama. Já as imagens *pos* (abreviação de positivo) são as imagens obtidas de pacientes que, segundo o software, possuem a doença.

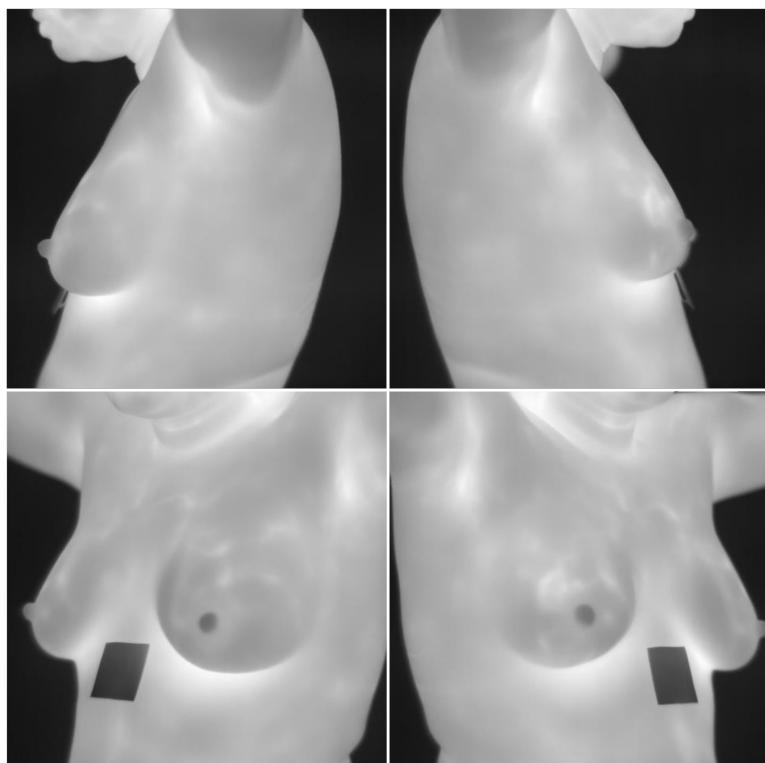


Figura 13: Imagens infravermelhas das mamas nos ângulos de 45° e 90° em escala de cinza. Fonte: (PROENG, 2012).

#### 4.1.2 Segmentação

A segunda etapa é a segmentação automática das imagens infravermelhas visando a obtenção da região de interesse a ser analisada. Este processo elimina regiões que foram capturadas na foto e que não são relevantes para o diagnóstico, como barriga, braços, fundo do ambiente, dentre outros.

Após a obtenção das imagens em escala de cinza é realizada uma extração manual de alguns fragmentos das imagens. Estes fragmentos (Figura 14) possuem um tamanho padrão e são recortados em aproximadamente 30% das imagens dos conjuntos de objeto

e fundo. Estes são utilizados para realizar o treinamento de um classificador baseado em HOG que irá distinguir diferentes regiões mamárias. Para um bom funcionamento do método proposto, é essencial que diversos fragmentos dos cantos contendo as pregas inframamárias sejam recortados.

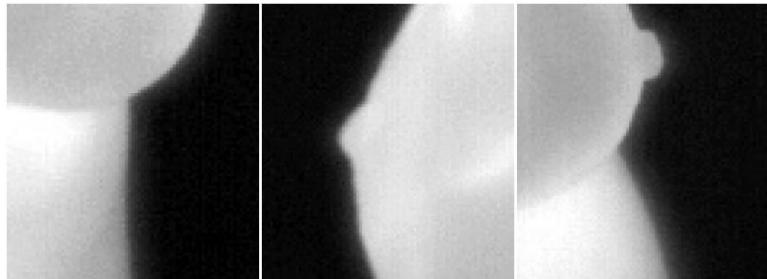


Figura 14: Fragmentos recortados das imagens. Fonte: Autora

Após realizar esta segmentação manual, os fragmentos são divididos em dois conjuntos: (i) imagens em que os cantos da prega inframamária estejam localizados no centro da imagem e (ii) imagens com as mais diversas regiões das mamas que não tenham cantos ao redor das pregas. Estes dois conjuntos, denominados como ( $IMG_{pos}$ ) e ( $IMG_{neg}$ ), respectivamente, são enviados para realizar o treinamento de um classificador. O classificador utilizado neste processo é a Máquina de Vetores Suporte em conjunto com o Histograma de Gradientes Orientados, descrito na Seção 2.5.1.1, pois é bastante eficaz para o reconhecimento ou detecção de objetos pela textura e/ou geometria.

Em seguida, os fragmentos são enviados ao algoritmo e são gerados os descritores de Histograma de Gradientes Orientados para todas as imagens dos dois conjuntos. Os parâmetros utilizados nesse algoritmo são tradicionais para problemas como esse, sendo eles: 8 histogramas de orientação dos gradientes, grades de células da ordem de 16x16 pixels, 4x4 células por bloco e norma L2 para a normalização dos blocos.

Os descritores obtidos pelo HOG são submetidos a Máquina de Vetores Suporte, classificador conhecido como SVM descrito na Seção 2.6.1.1, que possui os seguintes parâmetros: o termo de penalidade C é da ordem de 1.0 e a kernel empregada é a RBF. Além destes, o coeficiente de kernel é calculado de acordo com a Equação 4.1, em que  $nf$  é o número de características presente nos descritores.

$$c = \frac{1}{nf} \quad (4.1)$$

Após aplicado o SVM, o método identifica o contorno da prega inframamária

de todas as imagens contidas na base. Ao identificar, o método anota o par ordenado (coordenadas x e y) da prega inframamária para ser utilizada no segmentador.

Com as coordenadas das pregas inframamárias é aplicado o histograma de linha que delimita todo o segmento com baixa densidade na imagem, sendo este segmento provavelmente a região em que se encontra a prega inframamária. Contudo, este histograma é computado linha a linha até a região inferior da imagem (60% da área pertencente a figura, de cima para baixo), uma vez que a região da prega inframamária é localizada na parte inferior da mesma. Finalmente, a imagem segmentada automaticamente é obtida como mostra a Figura 15.

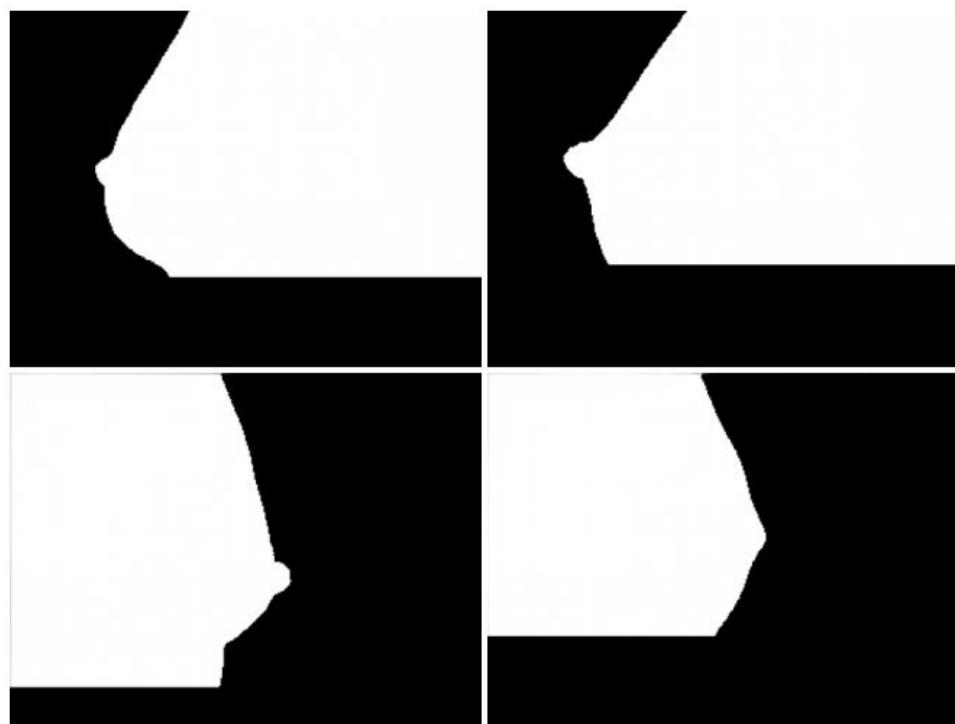


Figura 15: Imagem segmentada pela etapa de segmentação proposta. Fonte: Autora.

O método proposto neste trabalho foi implementado usando Python 3.5.4 x64 com as bibliotecas OpenCV para manipulação de imagens e Scikit-Learn para a utilização do método de Histograma de Gradientes Orientados. O algoritmo foi computado em uma máquina com processador Intel Core i5-2450M com 2.50Ghz e 6GB de Memória RAM, com sistema operacional Windows 7 Home Premium.

### 4.1.3 Classificação

A última etapa referente ao método proposto consiste na classificação das imagens infravermelhas laterais das mamas buscando um padrão entre elas para que o mesmo possa informar se há ou não a presença de anomalias.

Como consta na Seção 4.1.1, as imagens são armazenadas em duas pastas: *pos* (imagens com a doença presente) e *neg* (imagens com a doença ausente). As imagens contidas em cada pasta passam por uma verificação de formato, ou seja, somente serão processadas as imagens que estejam nos formatos: .PNG, .JPG ou .BMP. A seguir, as imagens que foram processadas são redimensionadas para 320x240 (largura x altura), que corresponde a uma redução em 50% da imagem para otimizar o processamento. Em seguida são retornadas duas listas: *listImagesP* referente a pasta *pos* e *listImagesN* referente a pasta *neg*. Ao final é criada uma lista *X* que concatene ambas.

Em seguida, cria-se uma lista (*Y*) que possui os rótulos de cada imagem contida em *X*. Estes rótulos são representados por 0 ou 1, onde 0 indica a ausência da doença na imagem e 1 a presença desta.

A próxima etapa consiste na divisão das imagens em dois conjuntos: treinamento e teste. O conjunto de treinamento tem por objetivo fazer o algoritmo extrair os atributos que definem imagens anômalas e não anômalas. Por meio deste, é possível identificar padrões e classificá-los. O conjunto de teste objetiva avaliar esse aprendizado. Para o modelo proposto, o conjunto de teste será formado por 20% do número total de imagens. Ao finalizar esta etapa, o algoritmo retorna duas listas (*X* e *Y*) de cada conjunto. Na lista *X* ficam armazenadas as imagens de entrada e na lista *Y* os resultados (diagnóstico) obtidos de cada imagem.

Para os classificadores de *Machine Learning* utilizados no presente trabalho fez-se necessário o uso de característica(s) para a realização da classificação. Para este atributo foi utilizado a variação tonal entre os pixels das imagens. Com isso os algoritmos analisam o pixel com uma determinada combinação de cores dentre os seus vizinhos e ao final realizava a rotulação da imagem (com ou sem câncer) .

Os algoritmos de classificação, apresentados na Seção 2.6.1, são responsáveis por ajustar o modelo, baseado no conjunto de treinamento, capaz de prever os rótulos das imagens contidas no conjunto de teste. Após este ajuste, o algoritmo retorna uma matriz

de confusão desses rótulos.

A matriz de confusão tem por objetivo avaliar a precisão da classificação. A função que cria esta matriz possui dois parâmetros de entrada, que são: os valores reais de verdadeiros positivos, falsos positivos, verdadeiros negativos e falsos negativos estimados pelo classificador. A diagonal principal desta matriz representa as classificações corretas, ou seja, quando os verdadeiros positivos e verdadeiros negativos são aferidos. Portanto, quanto mais alto forem os valores da diagonal, mais bem avaliado o método é. Os elementos da matriz que não pertencem a sua diagonal representam as estimativas erradas pelo classificador (falsos positivos e falsos negativos). Por fim, a última etapa do processo de classificação é a avaliação quantitativa através das Medidas Estatísticas abordadas na Seção 2.8.

O método proposto para classificação neste trabalho foi implementado usando Python 3.7.3 x32 com as bibliotecas OpenCV e Pandas para manipulação de imagens e Scikit-Learn para a utilização dos modelos de classificação. O algoritmo foi computado em uma máquina com processador Intel Core i5-7200U com 2.50Ghz e 8GB de Memória RAM, com sistema operacional Windows 10 x64.

# 5 Resultados

A avaliação do método proposto foi realizada através de comparações dos trabalhos relacionados descritos na Seção 3 com o trabalho proposto, empregando as Medidas Estatísticas apresentadas na Seção 2.8. Este capítulo será dividido em duas seções. A primeira (Seção 5.1) apresenta os resultados obtidos na etapa de segmentação e a segunda (Seção 5.2) descreve os resultados obtidos na etapa de classificação.

## 5.1 Resultados da Segmentação

A fim de se avaliar quantitativamente o modelo de segmentação proposto, foram calculadas as métricas apresentadas na Seção 2.8. Como resultado, o método obteve 89,6% de acurácia, 85,7% de sensibilidade, 94,3% de especificidade, 92,7% de preditividade positiva e 89,1% de preditividade negativa.

O modelo de segmentação proposto foi comparado com o trabalho de (OLIVEIRA, 2012) (Tabela 2), pois ambos apresentam como objetivo principal a segmentação automática da região em análise em imagens laterais das mamas. O presente trabalho se mostrou bastante eficiente e competitivo, uma vez que sua acurácia média (precisão do método) aproximou-se de 90%.

Tabela 2: Comparação de resultados entre (OLIVEIRA, 2012) e o presente trabalho.

Métrica	(OLIVEIRA, 2012)	Presente Trabalho
Acurácia Média	93%	89,6%
Sensibilidade	95%	85,7%
Especificidade	96%	94,3%
Preditividade Positiva	96%	92,7%
Preditividade Negativa	96%	89,1%

Fonte: Autora.

A sensibilidade, por sua vez, apresenta a relação para a classificação correta dos pixels considerados positivos nas imagens. A porcentagem de 85,7% descreve que o método proposto acarreta em maiores erros ao classificar os pixels que pertencem às regiões mamárias. Assim, a proporção de pixels que pertencem aos verdadeiros negativos (fundo da imagem) apresentam maior corretude, o que é visível na métrica de especificidade.

Esta apresentou o valor de 94,3%. Finalmente, as medidas de preditividade possuem taxas próximas a 90%, o que possibilita ao método a predição potencialmente correta dos pixels pertencentes ou não a região mamária.

## 5.2 Resultados da Classificação

A avaliação da etapa de classificação do método proposto foi realizada através do cálculo das métricas estatísticas de acurácia e sensibilidade, descritas na Seção 2.9 e por meio de uma comparação com o trabalho de (FRANCIS; SASIKALA; SARANYA, 2014), considerando que foi o único encontrado que se assemelha ao presente trabalho no que tange às imagens laterais.

A fim de se avaliar mais precisamente esta etapa, cada método de classificação utilizado neste trabalho foi executado 100 vezes. Em cada execução, gera-se um valor para cada uma das métricas estatísticas, e ao final computa-se a média e o desvio padrão desses valores. Este cálculo é essencial para se conferir a eficácia da classificação, uma vez que a média é uma medida estatística que representa todo o conjunto de dados. O desvio padrão, por sua vez, é igualmente importante por ser uma medida de dispersão em relação a média, tendo como objetivo indicar o quanto uniforme é o conjunto de dados analisado.

Dos trabalhos descritos no Capítulo 3, apenas o trabalho de Francis, Sasikala e Saranya (2014) realiza a classificação de imagens infravermelhas laterais das mamas. Com isso, para uma melhor avaliação do método proposto, a Tabela 3 apresenta uma comparação entre ambos.

Tabela 3: Comparação de resultados entre (FRANCIS; SASIKALA; SARANYA, 2014) e o presente trabalho.

Métricas	(FRANCIS; SASIKALA; SARANYA, 2014)	Presente trabalho
Acurácia Média	90,91%	83,02%
Sensibilidade	81,82%	27,10%
Especificidade	100%	96,58%

Os trabalhos destacados na tabela anterior se diferenciam no processo da obtenção das imagens processadas na classificação, uma vez que a base de imagens utilizada no presente trabalho pertencem a DMR (2012), enquanto as imagens utilizadas por SHE-EJA & SASIKALA (2014) são capturadas e preparadas pelos próprios autores, sendo assim não disponíveis para comparação com a proposta dessa monografia. Assim, alguns

fatores podem ser controlados pelo autor, desde a captura das imagens até o processo de classificação das mesmas, o que infere em um resultado melhor.

### 5.2.1 Acurácia

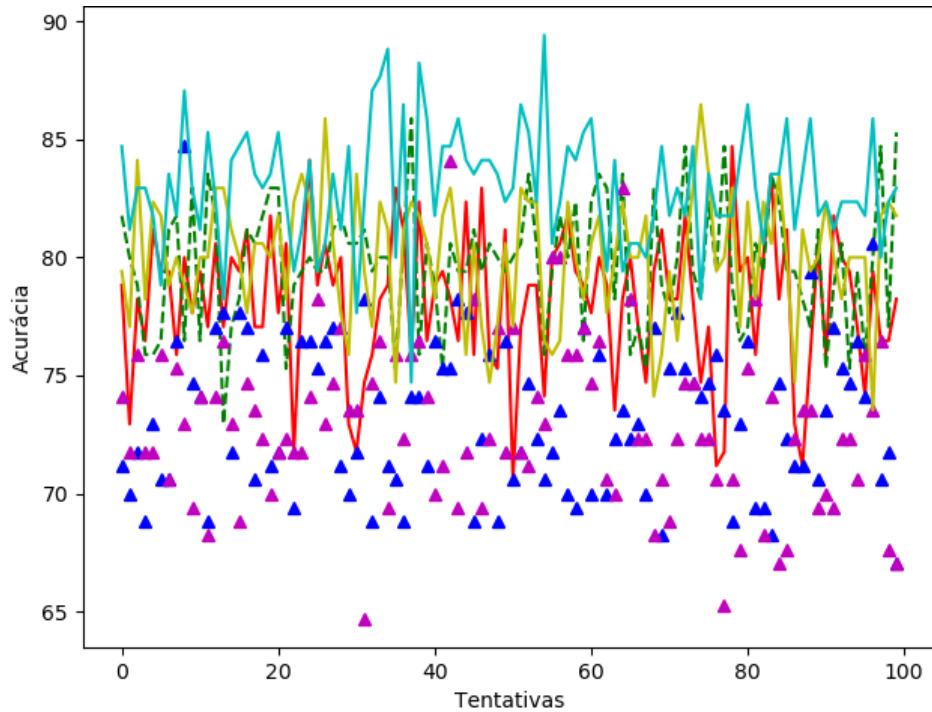
Como descrito na Seção 2.9, a acurácia (ACC) representa a eficácia do algoritmo em classificar uma imagem, seja ela proveniente de indivíduo saudável ou não. A Tabela 4 apresenta a média e o desvio padrão das acuráncias obtidas em cada um dos métodos de classificação.

Tabela 4: Resultado da acurácia em todos os métodos de classificação.

Acurácia (ACC)	SVM	LR	NB	DT	RF	KNN
Média	80,18	73,58	74,01	78,40	83,02	79,74
Desvio Padrão	2,31	2,99	3,52	2,80	2,48	2,65

Fonte: Autora.

Figura 16: Taxas de acurácia dos Métodos de Classificação.



Fonte: Autora.

A etapa de classificação das imagens infravermelhas laterais apresentou uma acurácia média próxima a 80% na maioria dos algoritmos de classificação utilizados. Dentre todos, o Floresta Randômica apresentou a maior precisão (83,02%) devido a composição das mais diversas combinações de características (rótulos) em sua estrutura. A Figura 16 apresenta todas as acuráncias obtidas em cada execução do algoritmo.

O traçado contínuo vermelho são as acurárias obtidas nas iterações do método de Árvore de Decisão, enquanto os amarelos representam o SVM e os na cor ciano o Floresta Randômica. Os segmentos seccionados verdes representam os valores obtidos pelo KNN. Os triângulos na cor magenta derivam-se do *Naive Bayes* e os azuis representam o Regressão Logística. Esta configuração é aplicada também a métrica de sensibilidade.

### 5.2.2 Sensibilidade

A sensibilidade é a capacidade do método em classificar corretamente as imagens proveniente dos pacientes doentes, como descrito na Seção 2.9. O presente trabalho apresenta uma sensibilidade média próxima a 40% na maioria dos métodos utilizados, como apresenta a Tabela 5.

Tabela 5: Resultado da Sensibilidade na Etapa de Classificação.

Sensibilidade (SEN)	SVM	LR	NB	DT	RF	KNN
Média	0	29,81	36,02	44,84	27,10	5,18
Desvio Padrão	0	8,11	8,18	8,60	6,33	3,84

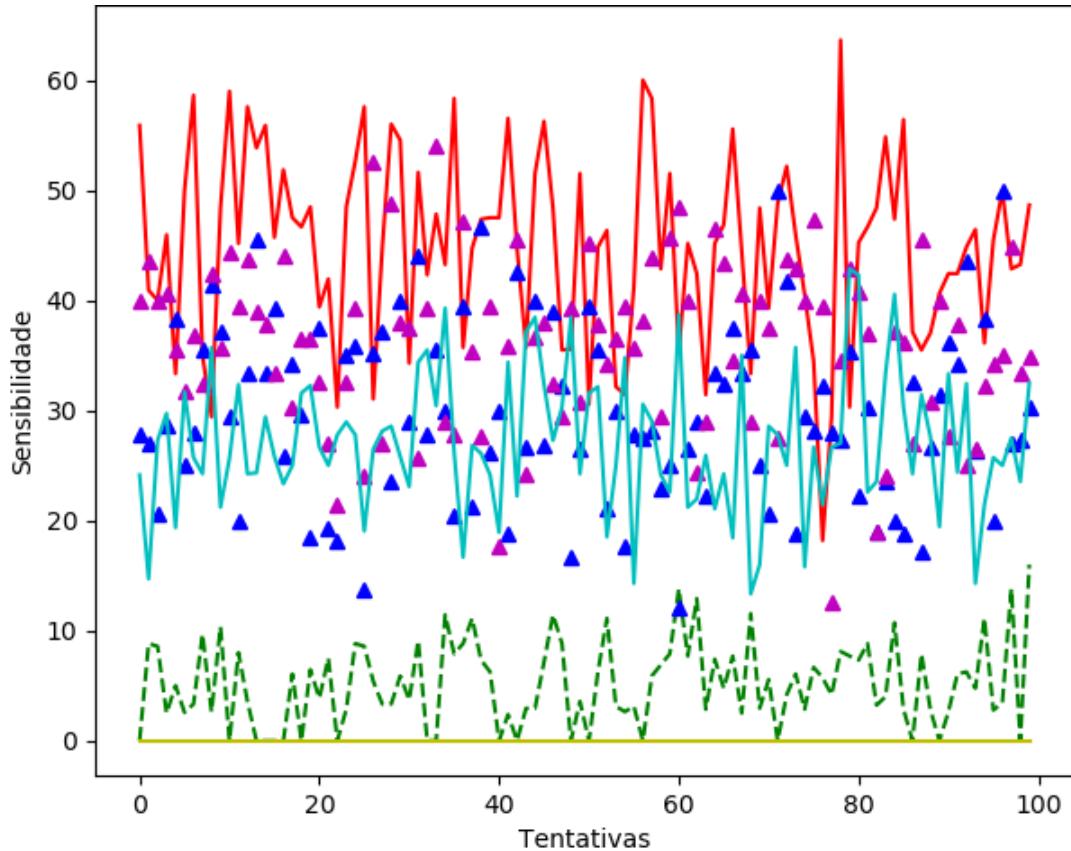
Fonte: Autora.

Dentre os métodos utilizados para a classificação das imagens (Seção 2.6) o Árvore de Decisão obteve a melhor taxa de precisão em classificar as imagens doentes, resultando em uma sensibilidade média de aproximadamente 45%. Contudo, o método apresentou uma certa dificuldade em classificar as imagens pertencentes aos pacientes com a doença devido ao baixo número de imagens contidas na base de dados.

Semelhante a acurácia, a sensibilidade também apresenta oscilações nas 100 iterações de cada algoritmo, como mostra a Figura 17. Devido a esta instabilidade os algoritmos devem ser executados mais de uma vez, e a precisão final deve ser retornada como a média dos valores obtidos em cada iteração.

Os segmentos contínuos de cores apresentados na Figura 17: vermelho, ciano e amarelo representam a taxa de sensibilidade, respectivamente, dos algoritmo Árvore de Decisão, Floresta Randômica e SVM. Enquanto o segmento segmentado verde pertence ao KNN. Os triângulos azuis e magenta representam o *Naive Bayes* e Regressão Logística, respectivamente.

Figura 17: Taxas de sensibilidade dos Métodos de Classificação.



Fonte: Autora.

### 5.2.3 Especificidade

A especificidade é a capacidade do método em classificar corretamente as imagens proveniente dos pacientes saudáveis, como descrito na Seção 2.9. O presente trabalho obteve uma especificidade média próxima a 100% na maioria dos métodos utilizados, como mostra a Tabela 6.

Tabela 6: Resultado da Especificidade na Etapa de Classificação.

Especificidade (ESP)	SVM	LR	NB	DT	RF	KNN
Média	99.50	84.53	83.04	86.57	96.58	97.75
Desvio Padrão	0.56	3.60	3.23	3.02	1.51	1.46

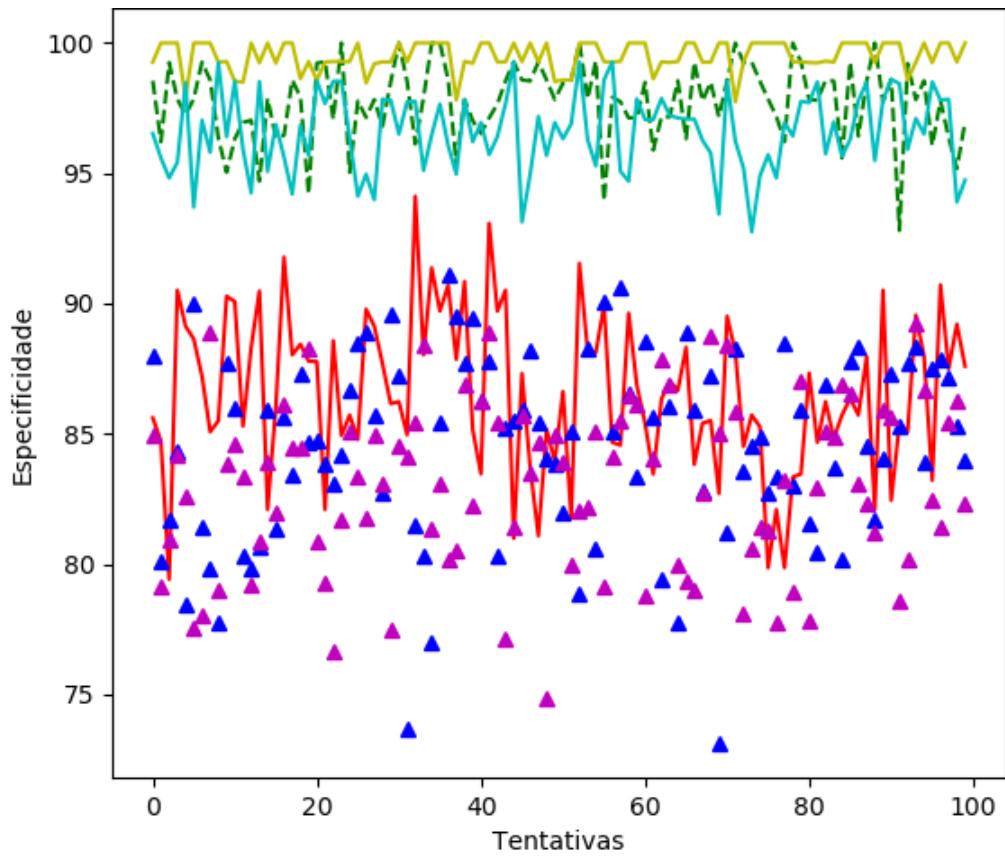
Fonte: Autora.

A melhor taxa de precisão ao classificar imagens saudáveis foi obtida pelo algoritmo SVM, que se aproximou de 100%. Enquanto os resultados mais baixos foram processados pelo *Naive Bayes* e ainda se aproximou de 83%. Todos os métodos se mostraram bastante eficiente em classificar estas imagens.

A Figura 18 apresenta os valores de especificidade obtidos nas 100 iterações de

cada método, em que cada representação gráfica (segmento ou triângulo) representa um algoritmo. Os segmentos apresentados na parte superior na cor amarelo descreve os melhores resultados obtidos para esta métrica advindos do algoritmo SVM. Os segmentos nas cores ciano e vermelho representam Floresta Randômica e Árvore de Decisão, respectivamente. Os triângulos apresentados em azul pertencem ao *Naive Bayes* e os na cor magenta são derivados do algoritmo Regressão Logística.

Figura 18: Taxas de especificidade dos Métodos de Classificação.



Fonte: Autora.

## 6 Conclusão

O presente trabalho é capaz de realizar a segmentação automática de imagens infravermelhas laterais das mamas, bem como a classificação delas, através de algoritmos automáticos qualificados para identificar as regiões convenientes, analisar, segmentar e classificar estas.

Atualmente a classificação de imagens infravermelhas laterais não é um problema muito presente na literatura, o que torna o presente trabalho enriquecedor para o campo de pesquisa e consequentemente para a criação de novas metodologias que possam auxiliar no diagnóstico do câncer de mama.

Diante dos resultados obtidos, o presente trabalho se mostra promissor e competitivo, pois apresenta um alto desempenho ao segmentar e classificar as imagens infravermelhas laterais, uma vez que as etapas de segmentação e classificação apresentaram uma precisão média de aproximadamente 80%.

Contudo, o método de classificação enfrentou problemas ao processar as imagens originais da base de dados. Para isso, um redimensionamento foi realizado, gerando uma perda de qualidade e de informações das imagens originais, implicando diretamente nos resultados finais.

Além disso, os métodos abordados na etapa de classificação não apresentaram uma eficácia em classificar as imagens pertencentes aos pacientes doentes, uma vez que a sensibilidade apresentou uma média relativamente baixa e um desvio padrão alto. Uma das razões que causaram essa imperfeição foi o baixo número de imagens estudadas pelos algoritmos. Diferente da precisão em classificar as imagens saudáveis, uma vez que a especificidade se aproximou de 100%.

É perceptível a oscilação que as métricas estatísticas são sujeitas ao decorrer das 100 iterações nos algoritmos de classificação, deste modo é possível ressaltar a importância da execução repetida dos métodos, bem como do cálculo da média e do desvio padrão da medida.

O principal trabalho futuro é a união das duas etapas, segmentação e classificação, com intuito de elevar a precisão do diagnóstico enviado ao paciente. Para isso, as imagens

retornadas pelo segmentador deverão ser inseridas na base de dados do classificador.

Outro trabalho futuro significativo é empregar redes neurais artificiais, como o Perceptron Multicamada ou mesmo arquiteturas provenientes de Deep Learning. Dessa forma, será possível saber se ocorrerá um aumento na acurácia e, principalmente, na sensibilidade dos resultados.

# Referências

- ABRIL, S. *Exames que identificam o câncer de mama*. 2018. Disponível em: <<https://saude.abril.com.br/bem-estar/exames-que-identificam-o-cancer-de-mama/>>. Acesso em: 29 ago. 2019.
- BAFFA, M. d. F. O.; LATTARI, L. G. Convolutional neural networks for static and dynamic breast infrared imaging classification. In: IEEE. *2018 31st SIBGRAPI Conference on Graphics, Patterns and Images (SIBGRAPI)*. [S.l.], 2018. p. 174–181.
- BARRETOS, H. D. *Informação: saiba quais são os tipos de câncer mais comuns no Brasil*. 2015. Disponível em: <<http://www.hcancerbarretos.com.br/82-institucional/noticias-institucional/1300-informacao-saiba-quais-sao-os-tipos-de-cancer-mais-comuns-no-brasil>>. Acesso em: 28 ago. 2019.
- CANCER. *Breast Cancer*. 2019. Disponível em: <<https://www.cancer.org/cancer/breast-cancer/about/what-is-breast-cancer.html>>. Acesso em: 28 ago. 2019.
- CANDES EMMANUEL E DEMANET, L. e. D. D. e. Y. L. Transformações rápidas em curva discretas. *Modelagem em várias escalas e simulação*, v. 5, p. 861–899, 2006.
- CERNA, L. R. Fusão de descritores de histogramas de gradientes para a detecção de faces baseado em uma cascata de classificadores. 2014.
- CÓRTE, A. C. R.; HERNANDEZ, A. J. Application of medical infrared thermography to sports medicine. *Revista Brasileira de Medicina do Esporte*, SciELO Brasil, v. 22, n. 4, p. 315–319, 2016.
- DALAL NAVNEET E TRIGGS, B. Histogramas de gradientes orientados para detecção humana. In: SOCIETY, I. C. (Ed.). *Anais da Conferência da Sociedade de Computação IEEE de 2005 sobre Visão Computacional e Reconhecimento de Padrões (CVPR'05) - Volume 1 - Volume 01*. Washington, DC, EUA: [s.n.], 2005. (CVPR '05), p. 886–893. ISBN 0-7695-2372-2. Disponível em: <<https://doi.org/10.1109/CVPR.2005.177>>.
- DPI/INPE. *Segmentação de Imagens*. 2006. Disponível em: <<http://www.dpi.inpe.br/spring/portugues/tutorial/segmentacao.html>>. Acesso em: 20 nov. 2019.
- DPI/INPE, S. *Classificação de Imagens*. 2006. Disponível em: <<http://www.dpi.inpe.br/spring/portugues/tutorial/classific.html>>. Acesso em: 03 dez. 2019.
- FRANCIS, S. V.; SASIKALA, M.; SARANYA, S. Detection of breast abnormality from thermograms using curvelet transform based feature extraction. *Journal of medical systems*, Springer, v. 38, n. 4, p. 23, 2014.
- GRIMM, A. M. *LEIS DE RADIAÇÃO (PARA CORPOS NEGROS)*. 2019. Disponível em: <<https://fisica.ufpr.br/grimm/aposmeteo/cap2/cap2-5.html>>. Acesso em: 20 nov. 2019.
- INCA. *Incidência de Câncer no Brasil*. 2018. Disponível em: <<http://www1.inca.gov.br/estimativa/2018/estimativa-2018.pdf>>. Acesso em: 13 dez. 2019.

- INCA. *Câncer de Mama*. 2019. Disponível em: <<https://www.inca.gov.br/tipos-de-cancer/cancer-de-mama>>. Acesso em: 28 ago. 2019.
- INCA. *O que é câncer?* 2019. Disponível em: <<https://www.inca.gov.br/o-que-e-cancer>>. Acesso em: 30 ago. 2019.
- INFRAREDMED. *Termografia: Totalmente segura e sem contraindicação*. 2017. Disponível em: <<https://infraredmed.com/termografia/>>. Acesso em: 30 ago. 2019.
- LESSA, V.; MARENGONI, M. Applying artificial neural network for the classification of breast cancer using infrared thermographic images. In: SPRINGER. *International Conference on Computer Vision and Graphics*. [S.l.], 2016. p. 429–438.
- LUCIDCHART. *O que é um diagrama de árvore de decisão?* 2019. Disponível em: <<https://www.lucidchart.com/pages/pt/o-que-e-arvore-de-decisao>>. Acesso em: 16 nov. 2019.
- MASTERY, M. L. *Naive Bayes for Machine Learning*. 2016. Disponível em: <<https://machinelearningmastery.com/naive-bayes-for-machine-learning/>>. Acesso em: 02 nov. 2019.
- MEDCALC. *Logistic regression*. 2019. Disponível em: <[https://www.medcalc.org/manual/logistic\\_regression.php](https://www.medcalc.org/manual/logistic_regression.php)>. Acesso em: 09 nov. 2019.
- OLIVEIRA, J. P. S. D. *Extração Automática da Região de Interesse em Imagens Térmicas Laterais das mamas*. Dissertação (Mestrado), 2012.
- ONCOGUIA. *Tipos de Câncer de Mama*. 2017. Disponível em: <<http://www.oncoguia.org.br/conteudo/tipos-de-cancer-de-mama/1382/34/>>. Acesso em: 13 dez. 2019.
- OPENCV. *Shi-Tomasi Corner Detector & Good Features to Track*. 2013. Disponível em: <[https://opencv-python-tutroals.readthedocs.io/en/latest/py\\_tutorials/py\\_feature2d/py\\_shi\\_tomasi/py\\_shi\\_tomasi.html](https://opencv-python-tutroals.readthedocs.io/en/latest/py_tutorials/py_feature2d/py_shi_tomasi/py_shi_tomasi.html)>. Acesso em: 16 nov. 2019.
- PHILOSOPHY, S. E. of. *Bayes' Theorem*. 2003. Disponível em: <<https://plato.stanford.edu/entries/bayes-theorem/>>. Acesso em: 20 nov. 2019.
- PORTELA FERNANDA AMORIM, G. M. J. M. e. M. M. C. *Tutorial de SVM*. 2017. Disponível em: <<https://lamfo-unb.github.io/2017/07/13/svm/>>. Acesso em: 20 out. 2019.
- PROENG. *Image Processing and Image Analyses Applied to Mastology*. 2012. Disponível em: <<http://visual.ic.uff.br/en/proeng/>>. Acesso em: 30 ago. 2019.
- RESMINI, R. Análise de imagens térmicas da mama usando descritores de textura. *Computer Institute, Master's Thesis, Federal Fluminense University*, 2011.
- SAÚDE, M. da. *Câncer de mama: sintomas, tratamentos, causas e prevenção*. 2019. Disponível em: <<http://www.saude.gov.br/saude-de-a-z/cancer-de-mama>>. Acesso em: 28 ago. 2019.
- SCIENCE, T. D. *Machine Learning Basics with the K-Nearest Neighbors Algorithm*. 2018. Disponível em: <<https://towardsdatascience.com/machine-learning-basics-with-the-k-nearest-neighbors-algorithm-6a6e71d01761>>. Acesso em: 23 nov. 2019.

SOUZA, A. *Algoritmo SVM (Máquina de Vetores de Suporte) a partir de exemplos e código (Python e R)*. 2019. Disponível em: <<https://pessoalex.wordpress.com/2019-04/10/algoritmo-svm-maquina-de-vetores-de-suporte-a-partir-de-exemplos-e-codigo-python-e-r/>>. Acesso em: 22 out. 2019.

STATSOFT. *Support Vector Machines (SVM) Introductory Overview*. 2019. Disponível em: <<http://www.statsoft.com/textbook/support-vector-machines>>. Acesso em: 05 nov. 2019.

VIDHYA, A. *Introduction to k-Nearest Neighbors: A powerful Machine Learning Algorithm (with implementation in Python & R)*. 2018. Disponível em: <<https://www.analyticsvidhya.com/blog/2018/03/introduction-k-neighbours-algorithm-clustering/>>. Acesso em: 23 nov. 2019.